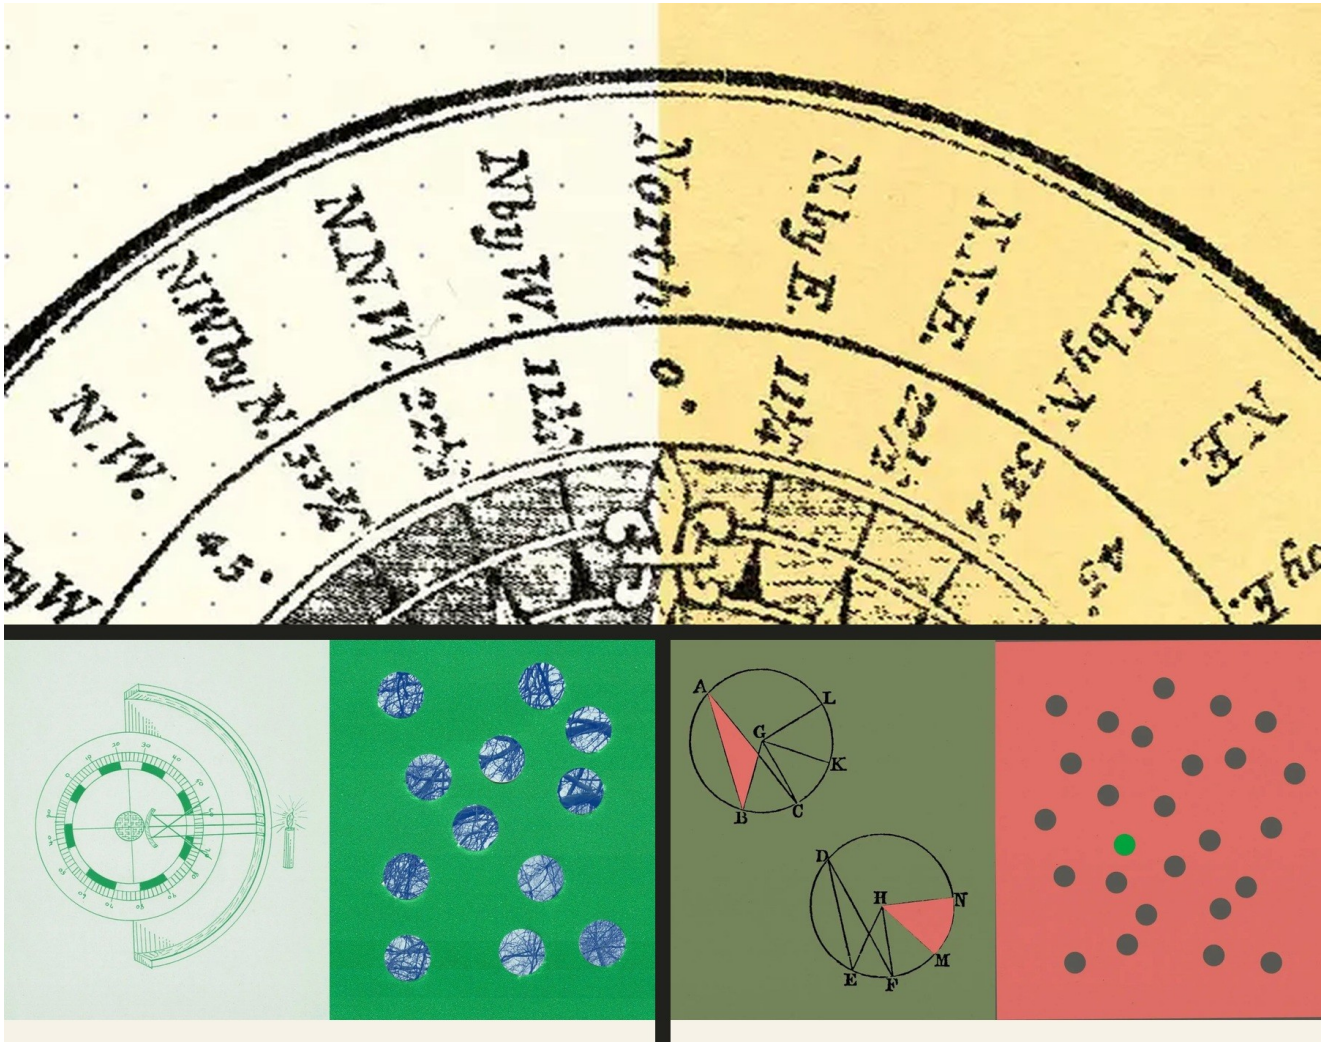


OBLIVION / MODEL SYSTEMS REPORT

GPT-OSS 20B & 120B

Architektur, Reasoning-Verhalten, Evaluation und Deployment-Engineering

Kritische technische Bewertung für das Oblivion-Team

DEUTSCHE AUSGABE | 26. Oktober 2026 | Research / 01

01 / OBLIVION RESEARCH

Managementbewertung

Zwei Betriebspunkte - ein technischer Entscheidungsrahmen

gpt-oss ist eine Familie von Open-Weight-Reasoning-Modellen. Entwickler können die Gewichte in einer selbst kontrollierten Infrastruktur prüfen, hosten und anpassen. Der Wert der Familie lässt sich nicht allein aus der Parameterzahl ableiten: Sparse Mixture-of-Experts-Berechnung, einstellbarer Reasoning-Aufwand, Harmony-basierte Tool-Interaktion und Apache-2.0-Lizenzierung bilden gemeinsam das technische Angebot; die veröffentlichte Nutzungspolitik bleibt zu beachten.

20B und 120B sind unterschiedliche Betriebspunkte. Das kleinere Modell ist leichter zu hosten und bei klar begrenzten Reasoning-Aufgaben konkurrenzfähig. Das größere Modell besitzt mehr Gesamtkapazität und erzielt bei mehreren Wissens-, Coding- und Tool-Evaluierungen höhere Werte, benötigt aber deutlich mehr Speicher und Rechenleistung. Es gibt keinen universellen Sieger.

Kennzahl	20B	120B
Parameter gesamt	20.91B	116.83B
Aktive Parameter je Token	3.61B	5.13B
Checkpoint-Größe	12.8 GiB	60.8 GiB
Ausgewählte Experten je Token	4	4

- Open-Weight bedeutet keine vollständig reproduzierbare Open-Source-Trainingsfreigabe; der komplette Pretraining-Korpus und die vollständige Trainingspipeline sind nicht offengelegt.
- Aktive Parameter beschreiben die ausgewählte Berechnung pro Token, nicht die gesamte gespeicherte Gewichtsmenge.
- gpt-oss wird nicht über ChatGPT oder die OpenAI-API bereitgestellt; der Betrieb liegt beim Betreiber oder Hosting-Anbieter.

Technisches Urteil: 20B ist der erste Kandidat für lokale, ressourcenbegrenzte Workflows. 120B sollte bei anspruchsvollem Wissen, mehrstufigem Coding und Aufgaben eingesetzt werden, bei denen Messungen von Oblivion den Qualitätsgewinn gegenüber den Infrastrukturkosten belegen. Auswahl nach Aufgabe und Evidenz, nicht nach Markenname oder Parameterzahl.

Aktualisierung des Umfangs: OpenAI führt außerdem gpt-oss-safeguard-20b und -120b als Research Preview. Diese Varianten dienen der policy-basierten Sicherheitsklassifikation und ersetzen nicht die allgemeinen 20B/120B-Modelle dieses Berichts.

02 / OBLIVION RESEARCH

Architektur und Sparse Computing

Warum aktive Parameter nicht der Modellgröße entsprechen

Beide Modelle sind autoregressive Transformer-Sprachmodelle mit Mixture-of-Experts-Blöcken (MoE). Für jedes Token wählt ein trainierter Router vier Experten aus einem größeren Pool. Nur diese Experten tragen zur spezialisierten Token-Berechnung bei; gemeinsame Schichten und Attention bleiben Teil des gesamten Forward-Passes.

Sparse Routing verbessert das Verhältnis zwischen Gesamtkapazität und Expertenberechnung pro Token. Es reduziert den Checkpoint jedoch nicht auf die Zahl aktiver Parameter: Alle Expertengewichte müssen im Speicher verfügbar sein oder von der Runtime geladen beziehungsweise ausgelagert werden.

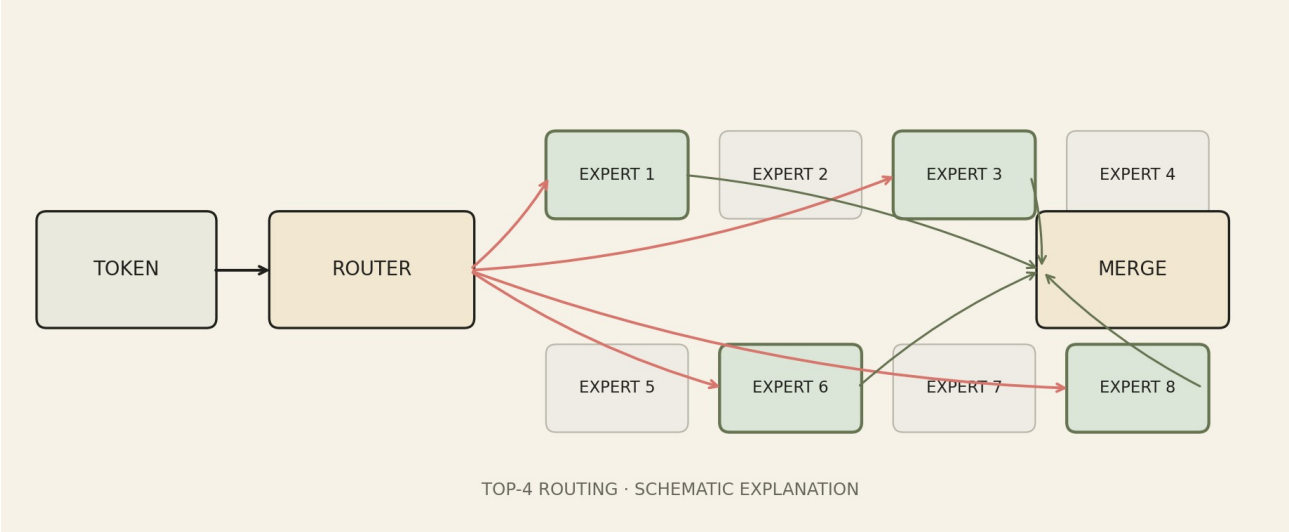


Abbildung 1. Schematische Top-4-MoE-Auswahl. Die Grafik erklärt das Prinzip und bildet nicht den internen Blockgraphen exakt ab.

Architekturmerkmal	20B	120B
Transformer-Schichten	24	36
Experten je MoE-Block	32	128
Ausgewählte Experten	4	4
Query-Heads	64	64
Key/Value-Heads	8	8
Attention-Head-Dimension	64	64

- Attention wechselt zwischen lokalem banded window und dichter Attention; die lokale Fensterbreite beträgt 128 Tokens.
- Grouped-Query-Attention nutzt 64 Query-Heads und 8 Key/Value-Heads.
- RoPE und YaRN unterstützen eine angegebene Kontextlänge von bis zu 131.072 Tokens in dichten Schichten.
- Der Stack umfasst RMSNorm, Pre-LN, SwiGLU und MXFP4-Post-Training-Quantisierung für MoE-Gewichte.

Interpretation: 3.61B und 5.13B sind sinnvolle Kennzahlen für aktive Berechnung je Token, aber keine verlässlichen RAM-/VRAM-Schätzungen. Die Speicherplanung muss bei der Checkpoint-Größe beginnen und KV-Cache, Runtime-Puffer, Batching und Betriebssystem-Overhead berücksichtigen.

03 / OBLIVION RESEARCH

Evaluation: Was sagen die veröffentlichten Werte?

Vergleichende Lesart der High-Reasoning-Ergebnisse

Die Tabelle reproduziert ausgewählte High-Reasoning-Werte aus OpenAIs Model Card. Tool- und No-Tool-Zeilen sind unterschiedliche Evaluierungsbedingungen. Scores verschiedener Benchmarks sind nicht direkt vergleichbar; vom Anbieter veröffentlichte Zahlen sind keine unabhängigen Replikationen durch Oblivion.

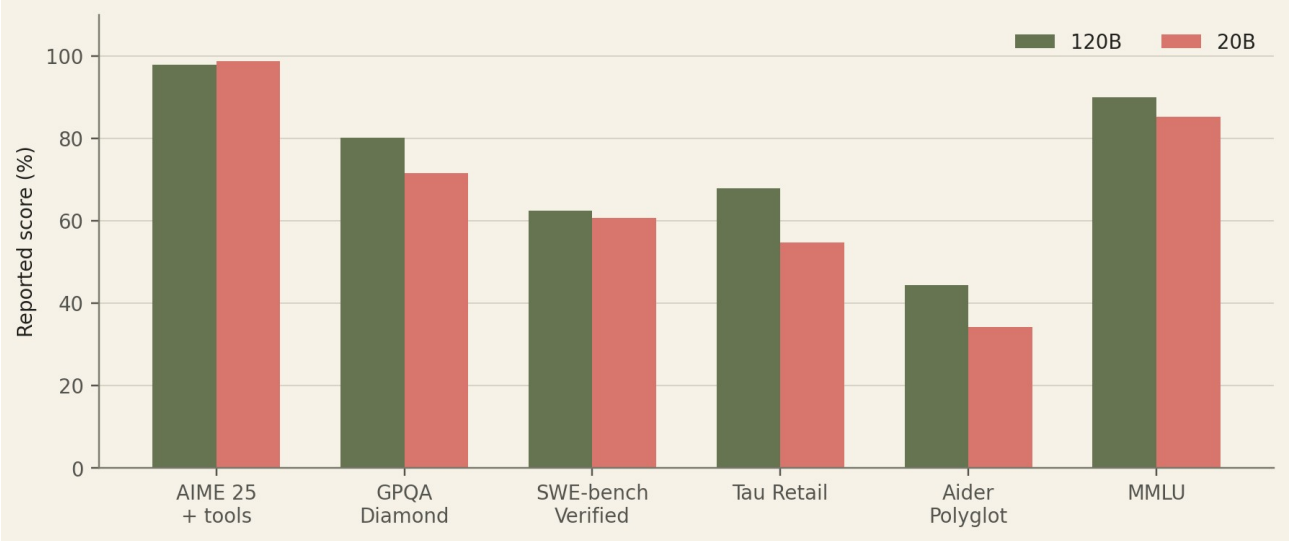


Abbildung 2. Ausgewählte Werte aus der offiziellen Model Card. Bei AIME 2025 mit Tools liegt 20B leicht vorn.

Benchmark / Einstellung	120B	20B	Vorteil
AIME 2025 · Tools	97.9	98.7	20B
GPQA Diamond · ohne Tools	80.1	71.5	120B
SWE-bench Verified	62.4	60.7	120B
τ-Bench Retail	67.8	54.8	120B
Aider Polyglot	44.4	34.2	120B
MMLU	90.0	85.3	120B

- 120B erzielt größere Vorteile bei GPQA Diamond, τ-Bench Retail und Aider Polyglot.
- 20B liegt beim toolgestützten AIME-2025-Ergebnis knapp vorn; das ist auf diese Aufgabe begrenzt und kein allgemeiner Leistungsumschwung.
- Codeforces Elo: 2.622 gegenüber 2.516 mit Tools und 2.463 gegenüber 2.230 ohne Tools (120B gegenüber 20B).

Die Tabelle darf nicht zu einer einzigen Rangliste verdichtet werden. Entscheidend ist der Oblivion-Aufgabenmix: Repository-Änderungen, lokale Extraktion, Mehrsprachigkeit, Tool-Zuverlässigkeit und Latenz können die Rangfolge verändern.

04 / OBLIVION RESEARCH

Reasoning, Harmony und Tool-Nutzung

Tool-Aufrufe allein machen noch keinen zuverlässigen Agenten

Der Reasoning-Aufwand lässt sich auf low, medium oder high einstellen. Mehr Aufwand kann die Genauigkeit bei schwierigen Aufgaben erhöhen, steigert jedoch meist Tokenverbrauch, Latenz und Rechenkosten. OpenAI berichtet, dass gpt-oss-20b bei hohem Reasoning-Aufwand im Mittel mehr als 20.000 Chain-of-Thought-Tokens je AIME-Aufgabe verwendete. Das ist ein Kosten- und Latenzhinweis, kein Produktionsbudget.

Die Modelle nutzen Harmony, ein serialisiertes Konversationsformat mit Nachrichtenbegrenzungen, Rollen, Kanälen und Kontrollflussmarkern. Tool-Aufrufe sind Assistant-Nachrichten an ein Tool; Tool-Antworten erscheinen unter dem Tool-Namen. Integrationen müssen den Kontrollfluss korrekt parsen und dürfen den Stream nicht als gewöhnlichen Fließtext behandeln.

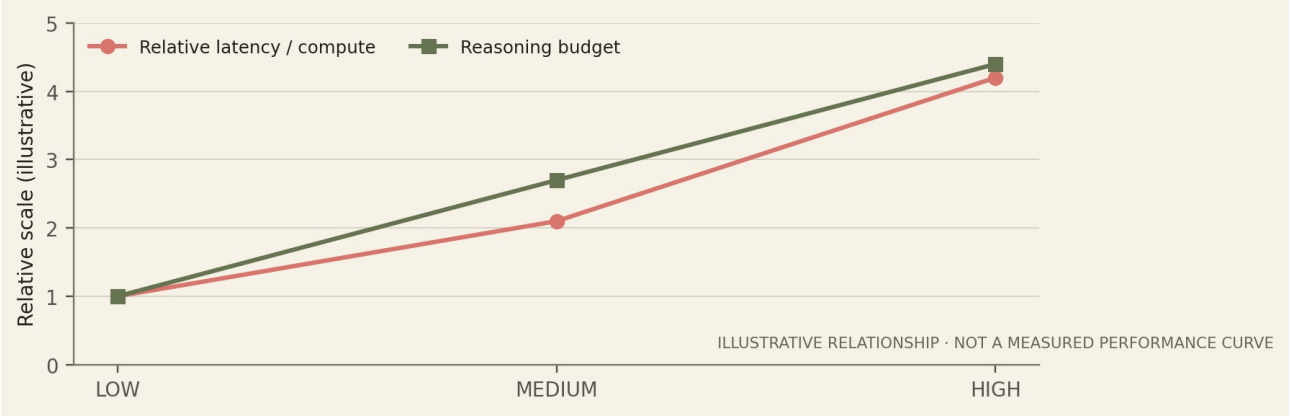


Abbildung 3. Qualitativer Zusammenhang zwischen Reasoning-Budget und Rechenaufwand; keine gemessene Kurve.

Kontrollebene	Technische Konsequenz
Reasoning-Aufwand	Je Aufgabe einstellen; Token- und Zeitlimits setzen.
Harmony-Parser	Rollen, Kanäle, Empfänger und Übergabemarker validieren.
Tool-Schemas	Argumente prüfen und unbekannte Funktionen ablehnen.
Zustandsautomat	Aufrufe, Wiederholungen, Timeouts und Abschluss verfolgen.

- Nutzerdaten, Tool-Ausgaben und Entwickleranweisungen in getrennten Vertrauensbereichen halten.
- Abgerufene Dokumente und Webseiten einschließlich eingebetteter Anweisungen als nicht vertrauenswürdige Inhalte behandeln.
- Wiederholungen, Abbruchbedingungen und Tool-Aufrufbudgets begrenzen.

Rohes internes Reasoning darf nicht als verlässliche Erklärung ausgegeben werden. OpenAI weist darauf hin, dass rohe CoT-Ausgaben Halluzinationen oder policy-widrige Formulierungen enthalten können. Stattdessen kurze Begründungen, Tool-Ausgaben, Quellen und Testergebnisse anzeigen.

05 / OBLIVION RESEARCH

Inference, Speicher und Deployment

Die Checkpoint-Größe ist nur die erste Position des Ressourcenbudgets

OpenAI gibt Checkpoint-Größen von 12.8 GiB für 20B und 60.8 GiB für 120B an. Das sind Speicherwerte der Gewichte und nicht der vollständige Runtime-Bedarf. KV-Cache, Kontextlänge, parallele Sequenzen, Allocator-Fragmentierung, Quantisierungsformat, Offload-Strategie und Runtime-Implementierung beeinflussen den tatsächlichen Bedarf.

Ein Kontextlimit von 131K bedeutet nicht, dass jede Anfrage den gesamten Kontext nutzen sollte. Lange Kontexte erhöhen den Druck auf den KV-Cache und können den Durchsatz senken. Ein Modell, das technisch geladen werden kann, kann für einen Produktworkflow trotzdem zu langsam, instabil oder teuer sein.

Ressourcenfaktor	Messgröße
Gewichte	Residenter VRAM/RAM, Format, Offload-Anteil
KV-Cache	Spitzenbedarf nach Kontextlänge und Parallelität
Latenz	Time-to-first-token, Abschlusszeit p50/p95
Durchsatz	Ein-/Ausgabetokens pro Sekunde bei Ziel-Batchgröße
Zuverlässigkeit	OOM-Rate, Neustarts, fehlerhafte Tool-Aufrufe
Kosten/Energie	GPU-Zeit und Energie je akzeptierter Aufgabe

- OpenAI positioniert 120B für eine einzelne 80-GB-GPU; genaue Runtime- und Kontextbedingungen müssen vor einer Betriebszusage geprüft werden.
- Für 20B darf ein nominales 16-GB-Ziel nicht mit garantiert flüssigem Betrieb gleichgesetzt werden; zu klären ist, ob VRAM, Unified Memory oder System-RAM gemeint ist.
- GPU, Treiber, Runtime-Version, Quantisierung, Batch, Kontext und Generierungsbudget für jeden Benchmark dokumentieren.

Deployment-Regel: Den vollständigen Produktpfad benchmarken, nicht nur das Laden des Modells. Erfolgreiche Aufgaben pro Einheit Latenz, Speicher, Energie und Betreiberintervention messen.

06 / OBLIVION RESEARCH

Sicherheit, Zuverlässigkeit und Open-Weight-Grenzen

Die Gewichte setzen Produktregeln nicht selbst durch

OpenAIs Model Card betont, dass Open-Weight-Deployment erhebliche Verantwortung an nachgelagerte Entwickler überträgt. Fine-Tuning und Systemkomposition können das Verhalten verändern; der Herausgeber kann Schutzmaßnahmen in abgeleiteten Deployments nicht zentral erzwingen. Apache 2.0 erlaubt breite Nutzung und Anpassung, die veröffentlichte Nutzungspolitik bleibt jedoch relevant.

Laut Model Card schneiden die Modelle bei Evaluierungen der Instruktionshierarchie sowie bei faktischen Tests wie SimpleQA und PersonQA im Allgemeinen schwächer ab als o4-mini. Das Dokument warnt außerdem vor Halluzinationen oder policy-widrigen Formulierungen in rohem internem Reasoning. Diese Grenzen sind besonders relevant, wenn das Modell Tools oder lokale Dateien nutzen kann.

Risiko	Erforderliche Oblivion-Kontrolle
Prompt Injection	Abgerufene Inhalte als Daten behandeln, nicht als Policy.
Überprivilegierte Tools	Allowlist, read-only als Standard, Freigabe für Schreibzugriffe.
Faktische Fehler	Quellenangaben, Retrieval-Prüfung und Claim-Verifikation.
Unsichere Code-Ausführung	Sandbox, Ressourcenlimits, kein uneingeschränktes Shell/Secret.
Stille Fehler	Strukturierte Logs, Event-IDs, begrenzte Retries und Alerts.

- OpenAI berichtet bei einigen StrongREJECT-Jailbreak-Evaluierungen Parität mit o4-mini, jedoch eine geringere Resistenz gegen Nutzer, die Systemanweisungen überschreiben wollen.
- Das Standardmodell 120B erreichte in den beobachteten Preparedness-Kategorien nicht die indikative Schwelle „High“; dies ist ein begrenztes Evaluationsergebnis, keine allgemeine Sicherheitsgarantie.
- Open Weights können nach der Veröffentlichung verändert werden. Das Produkt muss eigene Berechtigungen, Monitoring, Moderation und Auditierung durchsetzen.

Sicherheitsposition: Sicherheit ist eine Systemeigenschaft. Sie hängt von Modell, Prompt, Runtime, Tools, Berechtigungen, Datenquellen, menschlicher Prüfung und Monitoring ab - nicht allein vom Checkpoint.

07 / OBLIVION RESEARCH

Referenzarchitektur für Oblivion

Das Modell bleibt austauschbar; die Policy bleibt außerhalb des Modells

Oblivion sollte gpt-oss als austauschbares Reasoning-Backend behandeln. Eine separate Orchestrierungsschicht verantwortet Authentifizierung, Nutzerberechtigungen, Modellrouting, Kontextaufbau, Tool-Autorisierung, isolierte Ausführung, Evidenzprüfung und Audit-Ereignisse. Diese Architektur bleibt auch bei einem Austausch des Basismodells gültig.

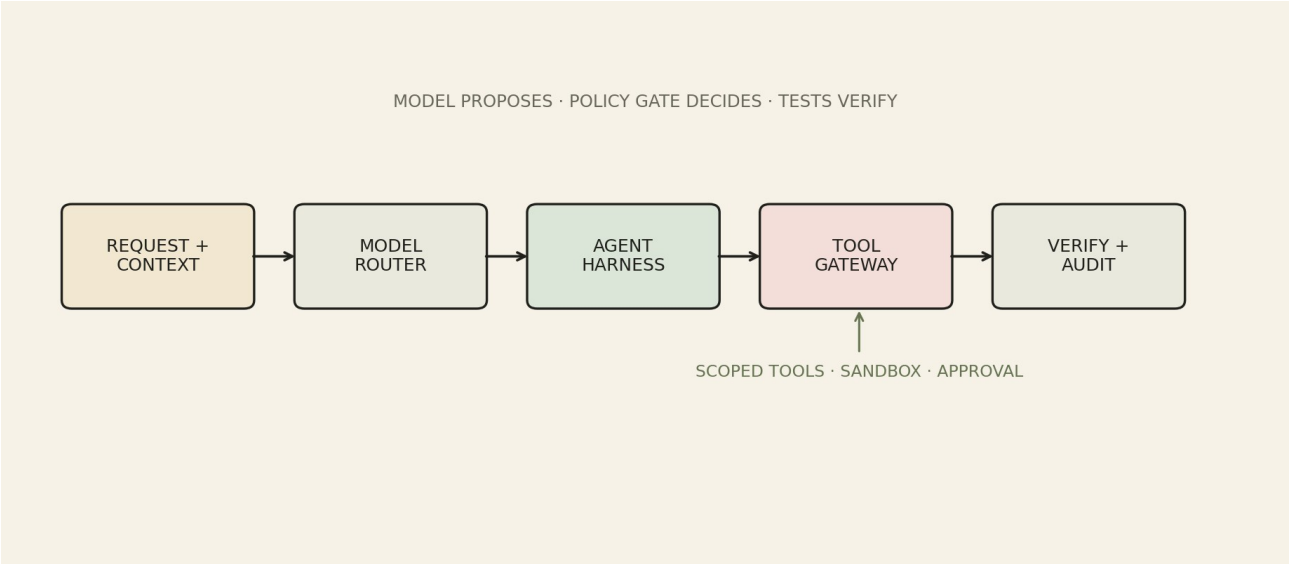


Abbildung 4. Empfohlene Trennung der Verantwortlichkeiten in einem Oblivion Agent Harness.

Schicht	Verantwortung
Identität und Policy	Sitzungsidentität, Tenant-Grenzen, Rollenprüfung
Model Router	20B/120B nach Aufgabe, Risiko, Budget und gemessener Qualität wählen
Agent Harness	Harmony-Adapter, Zustandsautomat, Token-/Zeitbudgets, begrenzte Retries
Tool Gateway	Allowlist, Schema-Prüfung, Sandbox, Freigabe
Verifier	Tests, Quellen, Diff-Prüfung, Ausgabegrenzen
Observability	Unveränderliche Audit-Ereignisse, Metriken, Traces und Incident Review

- 20B: Extraktion, Zusammenfassungen, erste Codeentwürfe, begrenzte lokale Analyse und risikoarme Aufgaben mit Validierung.
- 120B: schwierige Planung, komplexes Debugging, tiefgehendes Code-Review und Aufgaben mit nachgewiesenem Qualitätsgewinn.
- Löschen, Veröffentlichen, externe Nachrichten, Credential-Änderungen, Repository-Merges und andere zustandsändernde Aktionen benötigen menschliche Freigabe.

Das Modell darf eine Operation vorschlagen; das Tool Gateway entscheidet, ob sie autorisiert ist. Ein Modellscore ist niemals eine Ausführungsberechtigung.

08 / OBLIVION RESEARCH

Kritische Prüfung in drei Durchläufen

Annahmen hinterfragt, Evidenz geprüft, Design überarbeitet

Durchlauf 1 - Parameterzahl hinterfragen. Der erste Entwurf behandelte 20B implizit als „klein“ und 120B als „immer besser“. Beides greift zu kurz. Der 20B-Checkpoint umfasst vor Runtime-Overhead 12.8 GiB; außerdem liegt 20B in einer AIME-2025-Tool-Zeile vor 120B, aber bei mehreren Wissens- und Agent-Aufgaben dahinter. Revision: aufgabenspezifische Betriebspunkte statt universeller Rangfolge beschreiben.

Durchlauf 2 - Benchmark-Interpretation hinterfragen. Veröffentlichte Scores belegen nicht automatisch identische Prompts, Harness-Versionen, Wiederholungen oder Hardwarebedingungen. Hoher Reasoning-Aufwand erhöht den Rechenbedarf. Revision: jeden Score mit Einstellung kennzeichnen und vor der Auswahl eines Produktionsmodells auf einem Oblivion-Aufgabensatz reproduzieren.

Durchlauf 3 - Sicherheit durch Prompt hinterfragen. Ein Prompt kann bei veränderbaren Gewichten und externer Tool-Ausführung keine zuverlässige Policy erzwingen. Revision: Berechtigungsprüfung, Sandbox, Ausgabevalidierung und menschliche Freigabe in Code außerhalb des Modells umsetzen.

- Mindestens 100 anonymisierte Aufgaben aus realen Oblivion-Workflows erstellen.
- Persisch, Englisch, Deutsch, Japanisch und Koreanisch getrennt testen; englische Werte nicht auf andere Sprachen übertragen.
- Prompts, Runtime, Tools, Budgets und Hardware konstant halten; low/medium/high getrennt ausweisen.
- Aufgabenerfolg, Unit Tests, Halluzinationen, Injection-Resistenz, Tool-Missbrauch, p50/p95-Latenz, Spitzenspeicher und Energie messen.
- Read-only als Standard; Freigabe für Nebenwirkungen; vollständige Audit-Logs speichern.

Endposition: 20B ist ein ressourcenschonender Kandidat mit nennenswerter Reasoning-Fähigkeit; 120B bietet mehr Kapazität und stärkere Resultate in mehreren anspruchsvollen Evaluierungen. Keines der Modelle ist ein vollständiges Produkt. Der Wert von Oblivion entsteht durch Orchestrierung, Verifikation, Sicherheit und gemessene Zuverlässigkeit.

09 / OBLIVION RESEARCH

Methodik und Primärquellen

Herkunft der Evidenz, Reproduzierbarkeit und Grenzen

Dieser Bericht wurde als technische Bewertung für das Oblivion-Team neu verfasst. Architektur- und Benchmarkwerte werden OpenAIs veröffentlichter gpt-oss Model Card zugeschrieben. Aktuelle Hinweise zu Hosting und Safeguard-Varianten beruhen auf den OpenAI-Help-Center-Angaben vom 26. Oktober 2026. Harmony wurde anhand öffentlicher OpenAI-Dokumentation geprüft.

Kein Benchmark in diesem Bericht wurde unabhängig von Oblivion ausgeführt. Ergebnisse können sich mit Harness-Version, Prompt-Design, Reasoning-Aufwand, Tool-Implementierung, Quantisierung, Hardware, Decoding-Einstellungen und Evaluierungsprotokoll ändern. Die Diagramme sind erklärende redaktionelle Illustrationen, keine Originalgrafiken von OpenAI.

- [1] OpenAI, gpt-oss-120b & gpt-oss-20b Model Card, 5. August 2025. https://deploymentsafety.openai.com/gpt-oss/a2
- [2] OpenAI, Introducing gpt-oss, 5. August 2025. https://openai.com/index/introducing-gpt-oss/
- [3] OpenAI Help Center, Open-Weight-Modelle; aktueller Stand abgerufen am 26. Oktober 2026. https://help.openai.com/
- [4] OpenAI, Harmony-Dokumentation und öffentliches Repository. https://github.com/openai/harmony
- [5] OpenAI Cookbook, Harmony-Format. https://cookbook.openai.com/articles/openai-harmony
- [6] Hugging Face, offizielle OpenAI-gpt-oss-Repositories. https://huggingface.co/openai

Interpretationsgrenze: Dies ist keine OpenAI-Endorsement, keine Sicherheitszertifizierung und kein unabhängiger Benchmarkbericht. Lizenz und Nutzungspolitik sind vor Produktfreigabe anhand des aktuellen Quelltexts zu prüfen.