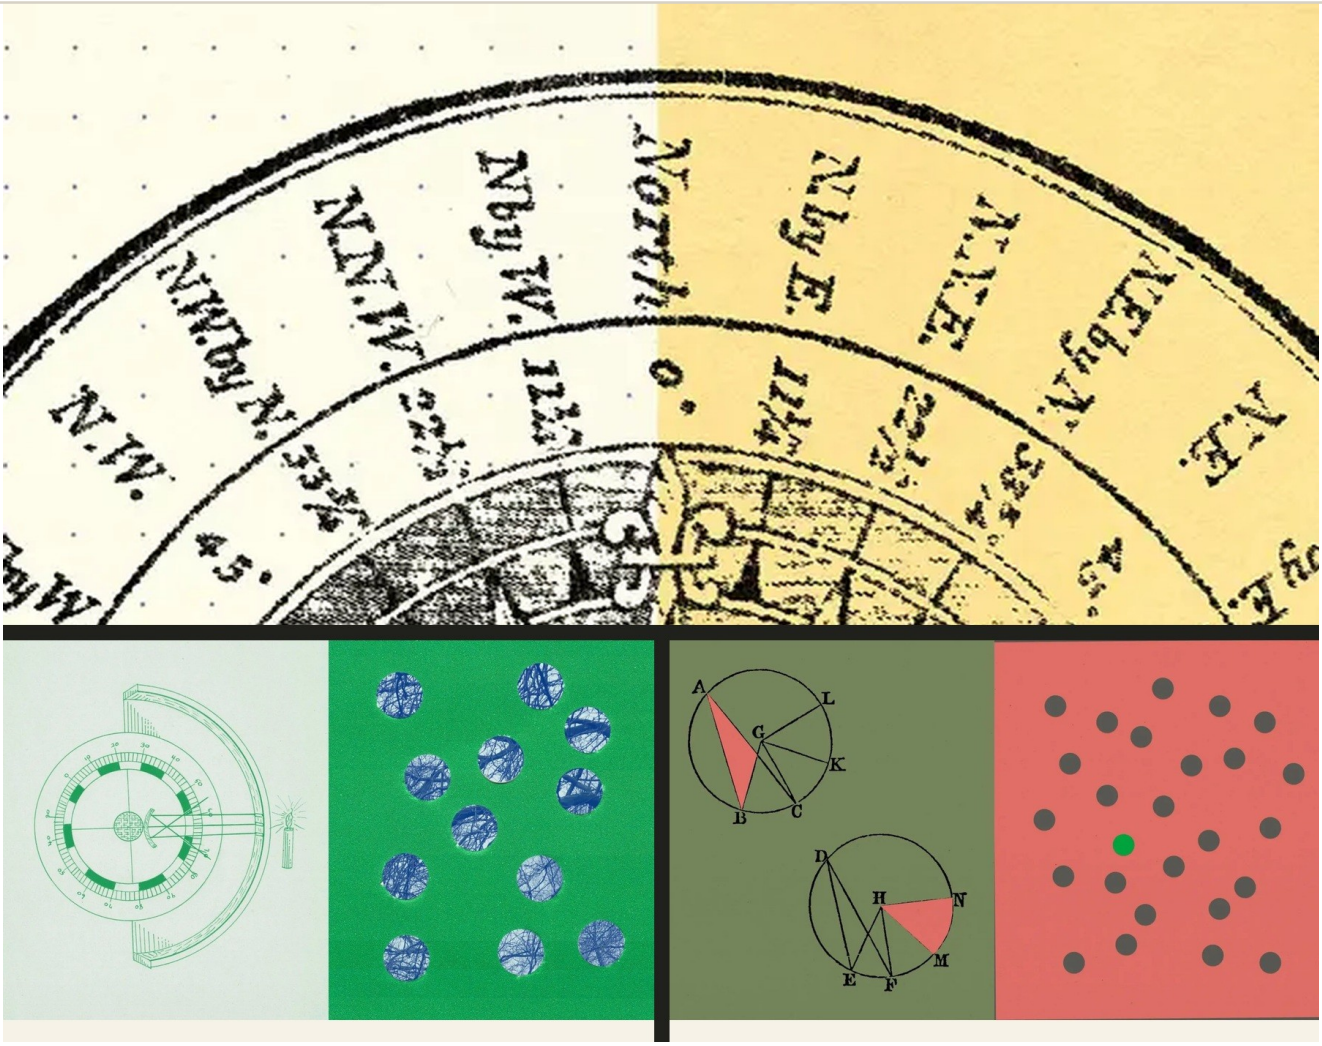


OBLIVION / MODEL SYSTEMS REPORT

GPT-OSS گزارش فنی خانوادهٔ

معماری، رفتار استدلالی، ارزیابی و مهندسی استقرار

ارزیابی انتقادی و مهندسی برای تیم Oblivion

Research / 01 | ۲۶ اکتبر ۲۰۲۶ | نسخهٔ فارسی

OBLIVION RESEARCH / ۰۱

ارزیابی مدیریتی

دو نقطهٔ عملیاتی؛ یک چارچوب تصمیم‌گیری مهندسی

gpt-oss خانواده‌ای از مدل‌های استدلالی با وزن‌های قابل‌دسترسی است که به توسعه‌دهنده اجازه می‌دهد وزن‌ها را در زیرساخت تحت کنترل خود میزبانی، بررسی و متناسب‌سازی کند. اهمیت این خانواده فقط با شمار پارامترها سنجیده نمی‌شود؛ ترکیب معماری پراکندهٔ Mixture-of-Experts، سطح استدلال قابل تنظیم، قالب تعاملی Harmony و مجوز Apache 2.0 (با رعایت سیاست استفادهٔ منتشرشده) ارزش اصلی آن را شکل می‌دهد.

نسخه‌های 20B و 120B دو نقطهٔ عملیاتی متفاوت‌اند. مدل کوچک‌تر برای استقرار ساده‌تر است و در برخی وظایف استدلالی محدود رقابت‌پذیری بالایی دارد. مدل بزرگ‌تر ظرفیت کلی بیشتری دارد و در چند ارزیابی دانش، کدنویسی و استفاده از ابزار نتیجهٔ قوی‌تری ثبت کرده، اما حافظه و محاسبات بسیار بیشتری می‌خواهد. هیچ‌کدام برندهٔ مطلق نیستند.

شاخص	**20B**	**120B**
پارامتر کل	20.91B	116.83B
پارامتر فعال در هر توکن	3.61B	5.13B
حجم checkpoint	12.8 GiB	60.8 GiB
متخصص انتخاب‌شده در هر توکن	4	4

- Open-weight به معنی انتشار کامل و بازتولیدپذیر فرایند آموزش نیست؛ پیکرهٔ کامل پیش‌آموزش و تمام زنجیرهٔ داده منتشر نشده‌اند.
- پارامتر فعال، محاسبات انتخاب‌شده برای هر توکن را توصیف می‌کند، نه حجم کامل وزن‌های ذخیره‌شده را.
- gpt-oss از طریق ChatGPT یا API شرکت OpenAI ارائه نمی‌شود؛ مسئولیت استقرار با اپراتور یا ارائه‌دهندهٔ میزبانی است.

جمع‌بندی مهندسی: 20B را نامزد نخست برای گردش‌کارهای محلی و محدود در نظر بگیرید؛ 120B را برای دانش دشوار، کدنویسی چندمرحله‌ای و وظایفی انتخاب کنید که اندازه‌گیری‌های Oblivion افزایش کیفیت آن را در برابر هزینهٔ زیرساخت توجیه کند. انتخاب باید بر اساس نوع وظیفه و شواهد باشد، نه نام مدل یا شمار پارامترها.

به‌روزرسانی دامنه: OpenAI اکنون gpt-oss-safeguard-20b و 120b را نیز به‌صورت پیش‌نمایش پژوهشی فهرست می‌کند. این شاخه‌ها برای استدلال ایمنی و طبقه‌بندی بر اساس سیاست ساخته شده‌اند و جایگزین مدل‌های عمومی این گزارش نیستند.

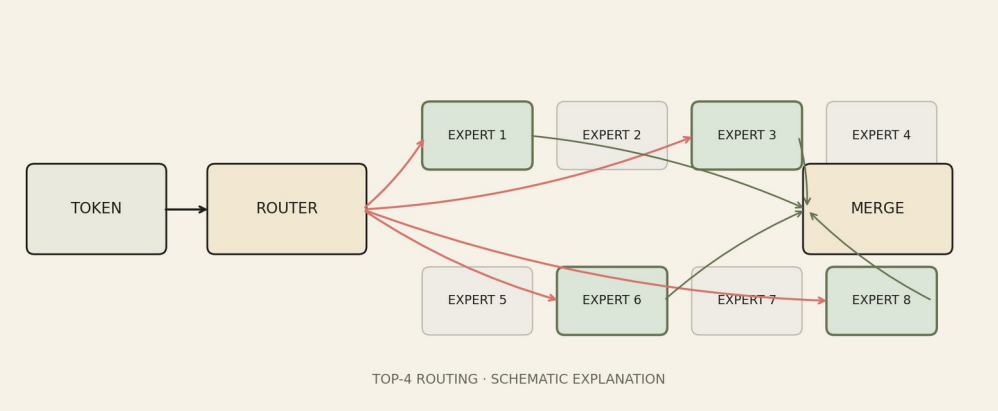
OBLIVION RESEARCH / ۰۲

معماری و محاسبات پراکنده

چرا پارامتر فعال با اندازهٔ مدل یکسان نیست

هر دو مدل، زبان‌مدل‌های خودبازگشتی Transformer هستند که از بلوک‌های Mixture-of-Experts یا MoE استفاده می‌کنند. برای هر توکن، یک مسیریاب آموزش‌دیده چهار متخصص را از مجموعه‌ای بزرگ‌تر انتخاب می‌کند. فقط متخصصان انتخاب‌شده در محاسبات تخصصی همان توکن مشارکت می‌کنند؛ اما لایه‌های مشترک و سازوکار توجه همچنان بخشی از اجرای کلی مدل‌اند.

این مسیریابی پراکنده نسبت ظرفیت کلی مدل به محاسبات تخصصی هر توکن را بهبود می‌دهد، اما checkpoint را به اندازهٔ پارامترهای فعال کوچک نمی‌کند. وزن تمام متخصصان باید در حافظه در دسترس باشند یا توسط runtime جابه‌جا و offload شوند.



شکل ۱. نمایش مفهومی مسیریابی *MoE* با انتخاب چهار متخصص؛ این تصویر برای توضیح است و نمودار داخلی واقعی مدل نیست.

ویژگی معماری	20B	120B
لایه‌های Transformer	24	36
متخصص در هر بلوک MoE	32	128
متخصص انتخاب‌شده در هر توکن	4	4
سرهای Query	64	64
سرهای Key/Value	8	8

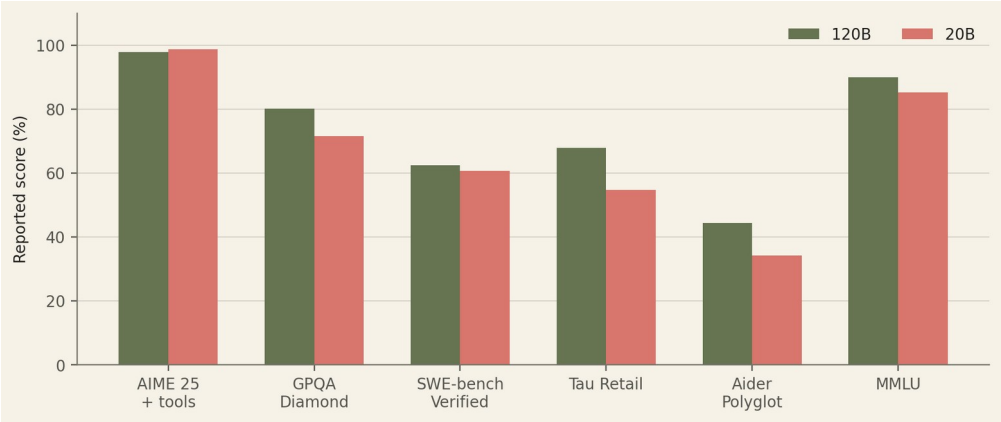
- توجه بین الگوهای پنجرهٔ محلی و توجه کامل جابه‌جا می‌شود؛ پهنای پنجرهٔ محلی 128 توکن گزارش شده است.
- توجه گروهی Query از 64 سر Query و 8 سر Key/Value استفاده می‌کند.
- RoPE و YaRN برای زمینه‌ای تا 131,072 توکن در لایه‌های dense گزارش شده‌اند.
- پشتهٔ معماری شامل RMSNorm، چیدمان Pre-LN، تابع SwiGLU و کوانتیزه‌سازی پس‌آموزشی MXFP4 برای وزن‌های MoE است.

OBLIVION RESEARCH / ۰۳

ارزیابی؛ نتایج منتشرشده چه می‌گویند؟

خوانش مقایسه‌ای نتایج در سطح استدلال بالا

جدول زیر نمونه‌ای از نتایج سطح استدلال بالا در Model Card رسمی OpenAI را بازنشر می‌کند. ردیف‌های دارای ابزار و بدون ابزار تنظیمات ارزیابی متفاوتی دارند. امتیاز benchmarkهای نامرتبط مستقیماً قابل مقایسه نیست و نتایج گزارش‌شده توسط سازنده، بازتولید مستقل Oblivion محسوب نمی‌شوند.



شکل ۲. چند امتیاز منتخب از *Model Card* رسمی. در نتیجهٔ *AIME 2025* با ابزار، امتیاز *20B* اندکی بالاتر است.

آزمون / تنظیم	**120B**	**20B**	مدل برتر
AIME 2025 · با ابزار	97.9	98.7	20B
GPQA Diamond · بدون ابزار	80.1	71.5	120B
SWE-bench Verified	62.4	60.7	120B
τ-Bench Retail	67.8	54.8	120B
Aider Polyglot	44.4	34.2	120B
MMLU	90.0	85.3	120B

- 120B در τ-Bench Retail، GPQA Diamond و Aider Polyglot فاصلهٔ بیشتری ایجاد می‌کند.
- 20B در ردیف AIME 2025 با ابزار کمی بالاتر است؛ این نتیجه وابسته به همان وظیفه است و برتری عمومی 20B را اثبات نمی‌کند.
- رتبهٔ Codeforces با ابزار 2622 در برابر 2516 و بدون ابزار 2463 در برابر 2230 گزارش شده است (120B در برابر 20B).

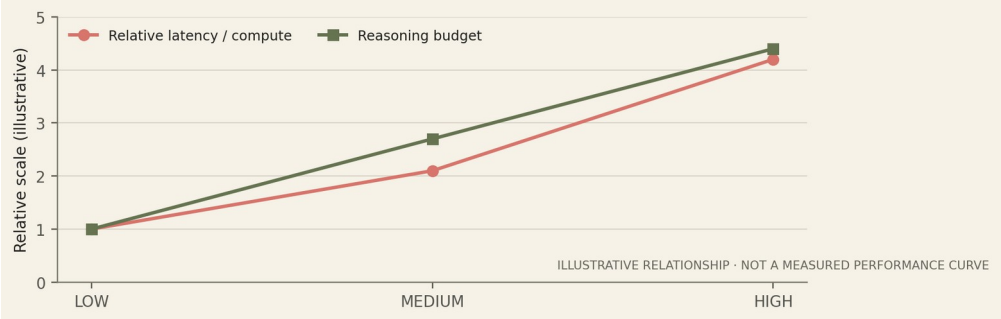
این جدول را به یک رتبه‌بندی کلی تقلیل ندهید. انتخاب مدل باید با ترکیب وظایف Oblivion انجام شود: تغییرات مخزن کد، استخراج محلی، پشتیبانی چندزبانه، قابلیت اتکای ابزار و تأخیر می‌توانند ترتیب مدل‌ها را تغییر دهند.

استدلال، **Harmony** و استفاده از ابزار

قابلیت فراخوانی ابزار هنوز به معنی عامل قابل‌اعتماد نیست

سطح استدلال در سه حالت low، medium و high قابل تنظیم است. تلاش بیشتر می‌تواند دقت بعضی مسئله‌های دشوار را بالا ببرد، اما معمولاً توکن تولیدی، تأخیر پاسخ و هزینهٔ محاسبات را افزایش می‌دهد. OpenAI گزارش کرده است که gpt-oss-20b در تنظیم high برای هر مسئلهٔ AIME به‌طور متوسط بیش از 20,000 توکن زنجیرهٔ استدلال مصرف کرده است. این عدد هشدار هزینه و تأخیر است، نه بودجهٔ پیشنهادی برای محصول.

مدل‌ها از Harmony استفاده می‌کنند؛ قالبی سریال‌شده برای مرزبندی پیام، نقش‌ها، کانال‌ها و نشانگرهای جریان کنترل. فراخوانی ابزار، پیام assistant خطاب به یک ابزار است و پاسخ ابزار با نام خود ابزار برمی‌گردد. یکپارچه‌سازی باید جریان کنترل را درست تفسیر کند و کل خروجی را متن ساده فرض نکند.



شکل ۳. رابطهٔ کیفی بودجهٔ استدلال با هزینهٔ محاسبات؛ نمایش مفهومی است و منحنی اندازه‌گیری‌شده نیست.

پیامد مهندسی	سطح کنترل
برای هر وظیفه تنظیم و سقف توکن/زمان تعیین شود.	سطح استدلال
نقش، کانال، گیرنده و نشانگر انتقال کنترل اعتبارسنجی شود.	Harmony parser
آرگومان‌ها اعتبارسنجی و توابع ناشناخته رد شوند.	طرح ابزار
فراخوانی، تکرار، timeout و تکمیل رهگیری شود.	ماشین حالت

- دادهٔ کاربر، خروجی ابزار و دستورهای توسعه‌دهنده در دامنه‌های اعتماد جدا نگه داشته شوند.
- اسناد بازیابی‌شده و صفحات وب، همراه با دستورهای درون آن‌ها، محتوای غیرقابل‌اعتماد تلقی شوند.
- تعداد retry، شرط توقف و سقف فراخوانی ابزار محدود باشد.

> زنجیرهٔ استدلال خام را به‌عنوان توضیح قطعی به کاربر نشان ندهید. OpenAI هشدار می‌دهد که CoT خام ممکن است حاوی توهم یا زبانی ناسازگار با سیاست باشد. به‌جای آن، خلاصهٔ قابل ممیزی، خروجی ابزار، استناد و شواهد آزمون را ارائه کنید.

OBLIVION RESEARCH / ۰۵

استنتاج، حافظه و استقرار

حجم checkpoint فقط نخستین ردیف بودجهٔ منابع است

حجم checkpoint مدل OpenAI 20B را 12.8 GiB و مدل 120B را 60.8 GiB گزارش می‌کند. این مقادیر حجم ذخیره‌سازی وزن‌ها هستند، نه نیاز کامل اجرای runtime. حافظهٔ KV، طول زمینه، تعداد توالی‌های هم‌زمان، تکه‌تکه‌شدن allocator، قالب quantization، سیاست offload و پیاده‌سازی runtime نیز بر نیاز واقعی اثر دارند.

سقف زمینهٔ 131K به این معنی نیست که هر درخواست باید از تمام آن استفاده کند. زمینهٔ طولانی فشار حافظهٔ KV را بالا می‌برد و ممکن است throughput را کاهش دهد. مدلی که از نظر فنی بارگذاری می‌شود، ممکن است برای گردش‌کار محصول بسیار کند، ناپایدار یا پرهزینه باشد.

چه چیزی اندازه‌گیری شود	عامل منابع
VRAM/RAM مقیم، قالب و نسبت offload	وزن‌ها
حافظهٔ اوج در طول زمینه و هم‌زمانی مختلف	KV cache
زمان تا اولین توکن و زمان تکمیل p50/p95	تأخیر
توکن ورودی/خروجی در ثانیه در batch هدف	Throughput
خطای OOM، راه‌اندازی مجدد و فراخوانی خراب ابزار	پایداری
زمان GPU و انرژی به‌ازای هر وظیفهٔ پذیرفته‌شده	هزینه/انرژی

- مدل OpenAI 120B را برای یک GPU هشتاد گیگابایتی معرفی می‌کند؛ پیش از تلقی آن به‌عنوان تضمین عملیاتی، شرایط دقیق runtime و context را بررسی کنید.
- برای 20B نیز اجرای روان را صرفاً از عدد اسمی 16GB نتیجه نگیرید؛ مشخص کنید ظرفیت مربوط به VRAM، حافظهٔ یکپارچه یا RAM سیستم است.
- برای هر benchmark، مدل GPU، درایور، نسخهٔ context، batch، quantization، runtime و بودجهٔ تولید را ثبت کنید.

> قاعدهٔ استقرار: کل مسیر محصول را benchmark کنید، نه فقط بارگذاری مدل را. تکمیل موفق وظیفه را در برابر زمان، حافظه، انرژی و مداخلهٔ اپراتور بسنجید.

OBLIVION RESEARCH / ۰۶

open-weight ایمنی، قابلیت اتکا و مرزهای

وزن‌های مدل به‌تنهایی سیاست محصول را اعمال نمی‌کنند

Model Card شرکت OpenAI یادآوری می‌کند که استقرار open-weight مسئولیت مهمی را به توسعه‌دهندگان پایین‌دست منتقل می‌کند. fine-tuning و ترکیب سامانه می‌تواند رفتار مدل را تغییر دهد و منتشرکننده نمی‌تواند کنترل متمرکز بر حفاظت‌های تمام مشتق‌ها داشته باشد. مجوز Apache 2.0 استفاده و تغییر گسترده را مجاز می‌کند، اما سیاست استفادهٔ منتشرشده همچنان مرتبط است.

طبق Model Card، مدل‌ها در ارزیابی‌های سلسله‌مراتب دستور و آزمون‌های صحت factual مانند SimpleQA و PersonQA عموماً از o4-mini ضعیف‌ترند. سند همچنین هشدار می‌دهد که استدلال داخلی خام ممکن است حاوی توهم یا زبان ناسازگار با سیاست باشد. این محدودیت‌ها هنگام دسترسی مدل به ابزار یا فایل محلی اهمیت بیشتری پیدا می‌کنند.

ریسک	کنترل ضروری در **Oblivion**
Prompt injection	محتوای بازیابی‌شده داده است، نه سیاست؛ دستور ابزار جدا باشد.
ابزار با مجوز زیاد	Allowlist، پیش‌فرض فقط‌خواندنی و تأیید صریح برای نوشتن.
خطای factual	استناد منبع، کنترل بازیابی و راستی‌آزمایی ادعا.
اجرای ناامن کد	Sandbox، محدودیت منابع و ممنوعیت shell و secret بدون محدودیت.
خرابی پنهان	Log ساختاریافته، شناسه رویداد، retry محدود و هشدار.

- OpenAI در برخی ارزیابی‌های jailbreak موسوم به StrongREJECT هم‌ترازی با o4-mini گزارش می‌کند، اما مقاومت ضعیف‌تری در برابر تلاش کاربر برای بازنویسی دستور سیستم دارد.
- مدل پیش‌فرض 120B در دسته‌های رصدشدهٔ Preparedness به آستانهٔ شاخص «High» نرسیده است؛ این نتیجه محدود به همان چارچوب ارزیابی است و تضمین ایمنی عمومی نیست.
- وزن‌های باز پس از انتشار قابل تغییرند؛ محصول باید مجوزها، پایش، moderation و سابقهٔ ممیزی خودش را اعمال کند.

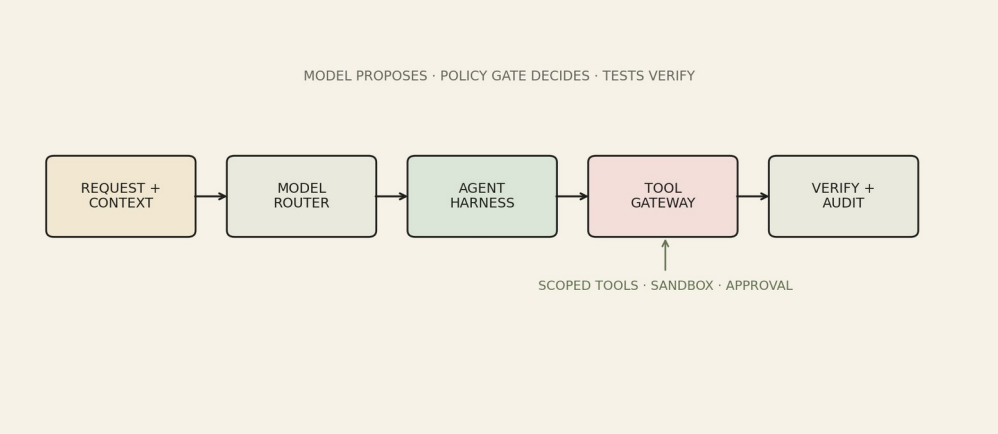
موضع امنیتی: ایمنی ویژگی کل سامانه است؛ به مدل، runtime، prompt، ابزار، مجوز، منبع داده، بازبینی انسانی و پایش وابسته است، نه فقط checkpoint.

OBLIVION RESEARCH / ۰۷

Oblivion معماری مرجع برای

مدل قابل تعویض باشد؛ سیاست بیرون از مدل بماند

Oblivion باید gpt-oss را یک backend استدلالی قابل تعویض بداند. یک لایهٔ orchestration مستقل باید احراز هویت، مجوز کاربر، انتخاب مدل، ساخت زمینه، تأیید ابزار، جداسازی اجرا، بررسی شواهد و رویدادهای ممیزی را مدیریت کند. این معماری حتی با تغییر مدل پایه نیز معتبر می‌ماند.



شکل ۴. جداسازی پیشنهادی مسئولیت‌ها برای *Agent Harness* در *Oblivion*.

مسئولیت	لایه
هویت نشست، مرز tenant و کنترل نقش‌ها	هویت و سیاست
انتخاب 20B/120B بر اساس وظیفه، ریسک، بودجه و کیفیت اندازه‌گیری‌شده	Model Router
مبدل Harmony، ماشین حالت، بودجهٔ توکن/زمان و retry محدود	Agent Harness
Allowlist، اعتبارسنجی sandbox، schema و تأیید	Tool Gateway
آزمون، استناد، بررسی diff و محدودیت خروجی	Verifier
رویداد ممیزی تغییرناپذیر، trace، metric و بازبینی رخداد	Observability

- نقش پیشنهادی 20B: استخراج، خلاصه‌سازی، پیش‌نویس اولیهٔ کد، تحلیل محلی محدود و وظایف کم‌ریسک همراه با اعتبارسنجی.
- نقش پیشنهادی 120B: برنامه‌ریزی دشوار، اشکال‌زدایی پیچیده، بازبینی عمیق کد و وظایفی که ارزیابی داخلی افزایش کیفیت معنادار را اثبات کند.
- حذف، انتشار، پیام خارجی، تغییر اعتبارنامه، merge مخزن و سایر عملیات تغییردهندهٔ وضعیت نیازمند تأیید انسانی باشند.

OBLIVION RESEARCH / ۰۸

بازبینی انتقادی در سه دور

ادعاها به چالش کشیده شدند؛ شواهد بررسی و طراحی اصلاح شد

دور اول - فرض شمار پارامترها. نسخهٔ اولیه به‌طور ضمنی 20B را «کوچک» و 120B را «همیشه بهتر» فرض می‌کرد. هر دو ساده‌سازی نادرست‌اند. checkpoint مدل 20B پیش از سربار runtime برابر 12.8 GiB است؛ همچنین 20B در یک ردیف AIME 2025 با ابزار از 120B بالاتر است، اما در چند وظیفهٔ دانش و عامل‌محور عقب می‌ماند. اصلاح: مدل‌ها به‌صورت نقطهٔ عملیاتی وابسته به وظیفه توصیف شوند، نه رتبه‌بندی مطلق.

دور دوم - تفسیر benchmark. امتیازهای منتشرشده به‌تنهایی یکسان بودن prompt، نسخهٔ harness، تکرار آزمون یا سخت‌افزار تمام وظایف را اثبات نمی‌کنند. استدلال سطح بالا هزینهٔ محاسبات را افزایش می‌دهد. اصلاح: هر امتیاز با تنظیماتش برچسب بخورد و پیش از انتخاب مدل پیش‌فرض، نتایج روی مجموعهٔ وظایف Oblivion بازتولید شود.

دور سوم - ایمنی مبتنی بر prompt. یک prompt نمی‌تواند در حضور وزن‌های قابل تغییر و اجرای ابزار خارجی، سیاست را به‌طور قابل اتکا تحمیل کند. اصلاح: کنترل مجوز، sandbox، اعتبارسنجی خروجی و تأیید انسانی باید در کد بیرون از مدل اجرا شوند.

- حداقل 100 وظیفهٔ ارزیابی از گردش‌کارهای واقعی و ناشناس Oblivion بسازید.
- فارسی، انگلیسی، آلمانی، ژاپنی و کره‌ای جداگانه آزموده شوند؛ از امتیاز انگلیسی به زبان‌های دیگر تعمیم ندهید.
- runtime، prompt، ابزار، بودجه و سخت‌افزار را ثابت نگه دارید؛ low/medium/high جدا گزارش شوند.
- نرخ موفقیت وظیفه، آزمون واحد، توهم، مقاومت در برابر injection، سوءاستفاده از ابزار، تأخیر p50/p95، حافظه و انرژی سنجیده شود.
- استقرار به‌صورت پیش‌فرض فقط‌خواندنی باشد؛ side effect با تأیید اجرا و تمام رویدادها ثبت شوند.

موضع نهایی: 20B نامزدی با منابع کمتر و توان استدلال قابل‌توجه است؛ 120B ظرفیت بالاتر و نتایج قوی‌تری در چند ارزیابی دشوار دارد. هیچ‌یک محصول کامل نیست. ارزش Oblivion باید از orchestration، راستی‌آزمایی، امنیت و قابلیت اتکای اندازه‌گیری‌شده حاصل شود.

OBLIVION RESEARCH / ۰۹

روش تحقیق و منابع اصلی

ردیابی شواهد، بازتولیدپذیری و محدودیت‌ها

این گزارش به‌عنوان ارزیابی مهندسی برای تیم Oblivion بازنویسی شده است. داده‌های معماری و benchmark به Model Card منتشرشده توسط OpenAI نسبت داده شده‌اند. نکات فعلی میزبانی و شاخهٔ Safeguard بر اساس راهنمای Help Center شرکت OpenAI در ۲۶ اکتبر ۲۰۲۶ است. رفتار Harmony نیز با مستندات عمومی OpenAI تطبیق داده شده است.

هیچ benchmark در این گزارش به‌طور مستقل توسط Oblivion اجرا نشده است. نتایج با نسخهٔ harness، طراحی prompt، سطح استدلال، پیاده‌سازی ابزار، quantization، سخت‌افزار، تنظیمات decoding و پروتکل ارزیابی تغییر می‌کنند. نمودارها تصاویر توضیحی و تحریریه‌ای هستند، نه نمودارهای اصلی منتشرشده توسط OpenAI.

- [۱] OpenAI، Model Card مدل‌های gpt-oss-120b و gpt-oss-20b، ۵ اوت ۲۰۲۵. https://deploymentsafety.openai.com/gpt-oss/a2
- [۲] ۵ OpenAI، Introducing gpt-oss اوت ۲۰۲۵. https://openai.com/index/introducing-gpt-oss/
- [۳] OpenAI Help Center، راهنمای مدل‌های open-weight؛ مشاهده در ۲۶ اکتبر ۲۰۲۶. https://help.openai.com/
- [۴] OpenAI، مستندات و مخزن عمومی قالب Harmony. https://github.com/openai/harmony
- [۵] OpenAI Cookbook، قالب Harmony. https://cookbook.openai.com/articles/openai-harmony
- [۶] Hugging Face، مخازن رسمی مدل‌های gpt-oss. https://huggingface.co/openai

مرز تفسیر: این سند تأییدیهٔ OpenAI، گواهی امنیتی یا گزارش benchmark مستقل نیست. پیش از انتشار محصول، متن جاری مجوز و سیاست استفاده بررسی شود.