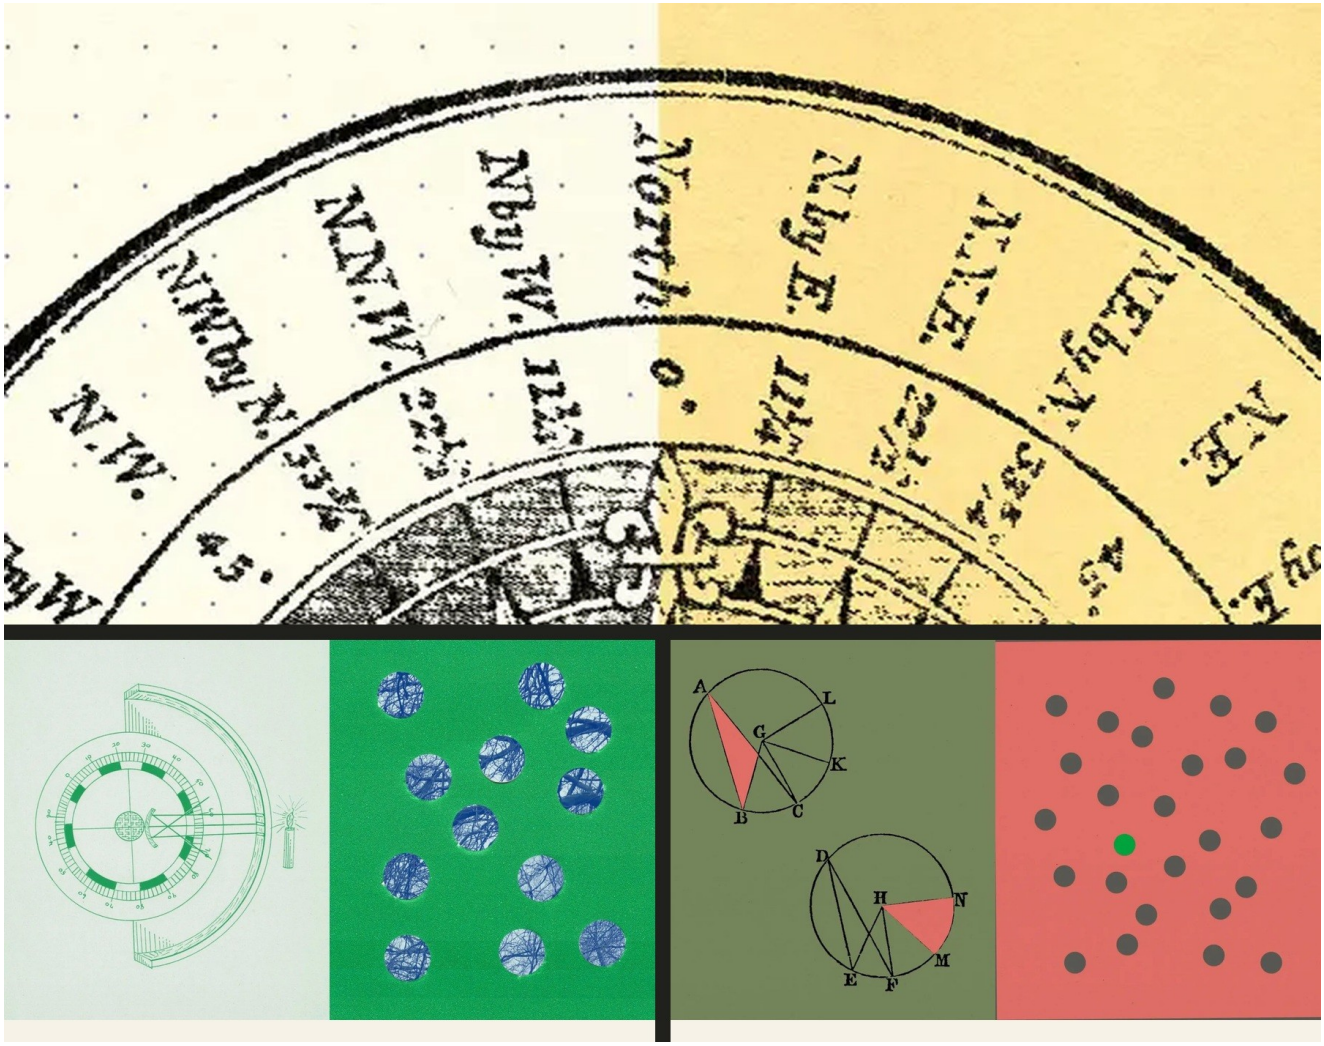


OBLIVION / MODEL SYSTEMS REPORT

GPT-OSS 20B / 120B

アーキテクチャ、推論特性、評価、デプロイメント設計

Oblivion エンジニアリングチーム向け技術評価

日本語版 | 2026 年 10 月 26 日 | Research / 01

01 / OBLIVION RESEARCH

エグゼクティブ評価

2 つの運用ポイントと、1 つの技術的な判断基準

gpt-oss は、開発者が自ら管理するインフラ上で重みを調査、ホスト、調整できるオープンウェイトの推論モデル群である。その価値はパラメータ数だけでは測れない。疎な Mixture-of-Experts 計算、調整可能な推論強度、Harmony 形式のツール連携、Apache 2.0 ライセンス（公開された利用ポリシーへの準拠が前提）が組み合わさっている。

20B と 120B は異なる運用ポイントとして扱うべきである。小型モデルはホストしやすく、範囲が限定された推論タスクでは高い競争力を示す。大型モデルは総容量が大きく、知識、コーディング、ツール利用の複数評価で高い結果を示す一方、より多くのメモリと計算資源を必要とする。万能の勝者はいない。

指標	20B	120B
総パラメータ	20.91B	116.83B
トークンごとの活性パラメータ	3.61B	5.13B
チェックポイント容量	12.8 GiB	60.8 GiB
トークンごとの選択エキスパート	4	4

- オープンウェイトは、完全に再現可能なオープンソース学習の公開を意味しない。事前学習コーパス全体と完全な学習パイプラインは公開されていない。
- 活性パラメータはトークンごとに選択された計算を表し、保存すべき重み全体の容量ではない。
- gpt-oss は ChatGPT または OpenAI API 経由では提供されない。運用責任は運用者またはホスティング事業者にある。

技術的結論：ローカルかつ制約のあるワークフローでは 20B を最初の候補とする。難しい知識、多段階コーディング、品質向上がインフラコストに見合うことを Oblivion の測定で確認できたタスクでは 120B を検討する。モデル名やパラメータ数ではなく、タスクと証拠に基づいて選択する。

範囲の更新：OpenAI は gpt-oss-safeguard-20b および-120b も研究プレビューとして掲載している。これらはポリシーに基づく安全性分類向けであり、本レポートの汎用 20B/120B モデルの代替ではない。

02 / OBLIVION RESEARCH

アーキテクチャと疎な計算

活性パラメータはモデル容量と同じではない

両モデルは Mixture-of-Experts（MoE）ブロックを備えた自己回帰 Transformer 言語モデルである。各トークンについて、学習済みルーターが大きな候補群から 4 つのエキスパートを選択する。選択されたエキスパートのみがそのトークンの専門計算に参加するが、共有レイヤーと Attention も全体の forward pass に含まれる。

疎なルーティングはモデル全体の容量とトークンごとの専門計算の比率を改善する。しかしチェックポイントを活性パラメータ数まで縮小するわけではない。すべてのエキスパート重みをメモリ上に保持するか、runtime がロード／オフロードする必要がある。

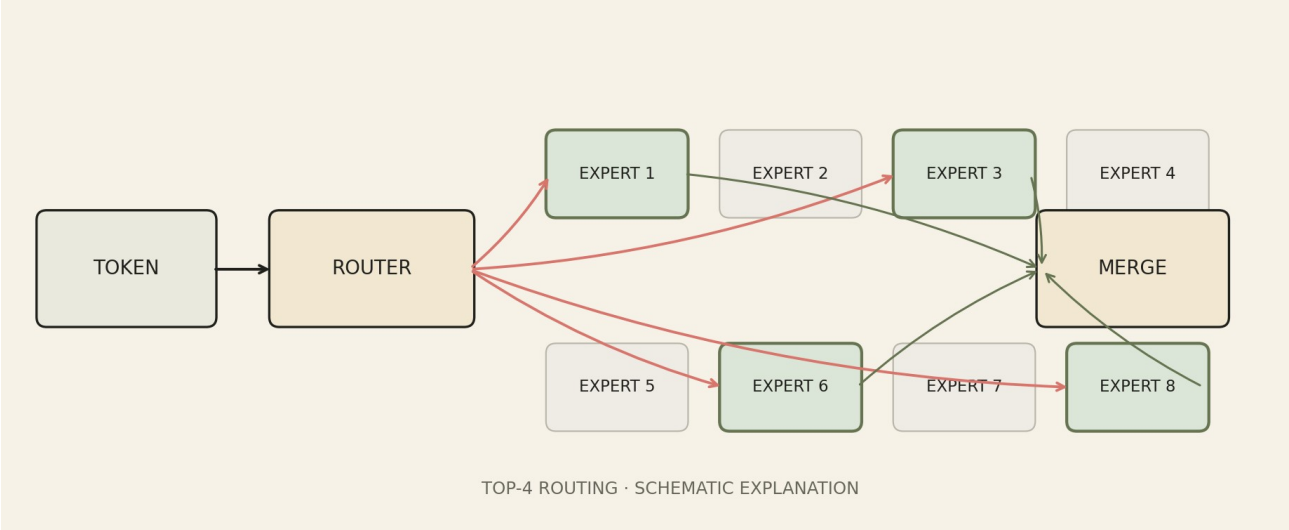


図 1. Top-4 MoE ルーティングの概念図。内部ブロック構造をそのまま再現したものではない。

構成要素	20B	120B
Transformer レイヤー	24	36
MoE ブロックごとのエキスパート	32	128
選択エキスパート	4	4
Query ヘッド	64	64
Key/Value ヘッド	8	8
Attention ヘッド次元	64	64

- Attention はローカルな banded window と dense attention を交互に使用する。ローカル窓幅は 128 トークン。
- Grouped-Query Attention は 64 個の Query ヘッドと 8 個の Key/Value ヘッドを使用する。
- RoPE と YaRN により、dense レイヤーで最大 131,072 トークンのコンテキストが報告されている。
- 構成には RMSNorm、Pre-LN、SwiGLU、MoE 重みへの MXFP4 事後学習量子化が含まれる。

解釈：3.61B と 5.13B はトークンごとの活性計算量を示す有用な指標だが、RAM/VRAM の必要量を示すものではない。メモリ計画ではチェックポイント容量に加え、KV キャッシュ、runtime バッファ、batch、OS オーバーヘッドを含める。

03 / OBLIVION RESEARCH

評価：公開スコアが示すこと

高推論設定の結果を比較して読む

以下は OpenAI の Model Card から選択した高推論設定の数値である。ツールあり／なしの行は異なる評価条件を示す。異なる benchmark のスコア同士は直接比較できず、ベンダー公開値は Oblivion による独立再現ではない。

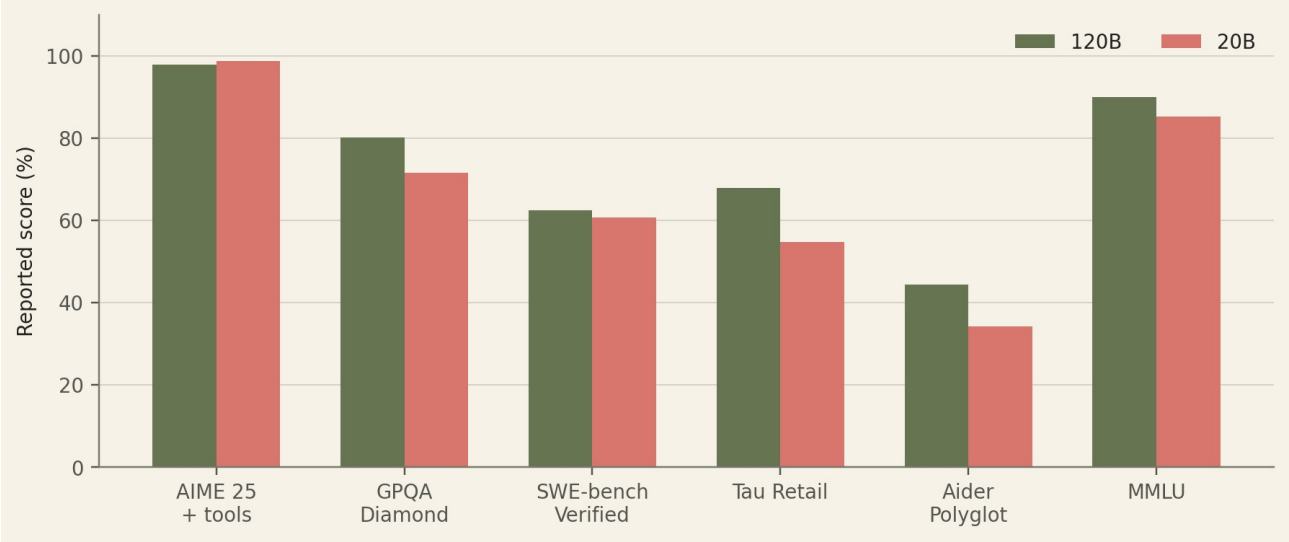


図 2. OpenAI 公開 Model Card から再構成したスコア。AIME 2025 のツールあり設定では 20B がわずかに高い。

Benchmark / 条件	120B	20B	優位
AIME 2025・ツールあり	97.9	98.7	20B
GPQA Diamond・ツールなし	80.1	71.5	120B
SWE-bench Verified	62.4	60.7	120B
τ-Bench Retail	67.8	54.8	120B
Aider Polyglot	44.4	34.2	120B
MMLU	90.0	85.3	120B

- 120B は GPQA Diamond、τ-Bench Retail、Aider Polyglot でより大きな差を示す。
- 20B はツールあり AIME 2025 の行でわずかに上回る。この結果は特定タスクに限られ、全般的な逆転を意味しない。
- Codeforces Elo はツールありで 2622 対 2516、ツールなしで 2463 対 2230（120B 対 20B）。

単一のランキングに集約しないこと。Oblivion のタスク構成、すなわちリポジトリ変更、ローカル抽出、多言語対応、ツール信頼性、レイテンシによってモデルの順位は変わり得る。

04 / OBLIVION RESEARCH

推論、Harmony、ツール利用

ツールを呼び出せることと、信頼できるエージェントであることは別

推論強度は low、medium、high に設定できる。推論量を増やすと難問の精度が向上する場合がある一方、生成トークン、応答レイテンシ、計算コストも増える。OpenAI は、高推論設定の gpt-oss-20b が AIME の各問題で平均 20,000 を超える chain-of-thought トークンを使用したと報告している。これはコストとレイテンシへの警告であり、本番予算ではない。

モデルは Harmony を使用する。Harmony はメッセージ境界、ロール、チャネル、制御フローマーカーを保持するシリアライズ形式である。ツール呼び出しはツール宛ての assistant メッセージで、ツール応答はツール名の下に返る。統合側は制御フローを正しく解析し、全体を通常の文章として扱ってはならない。

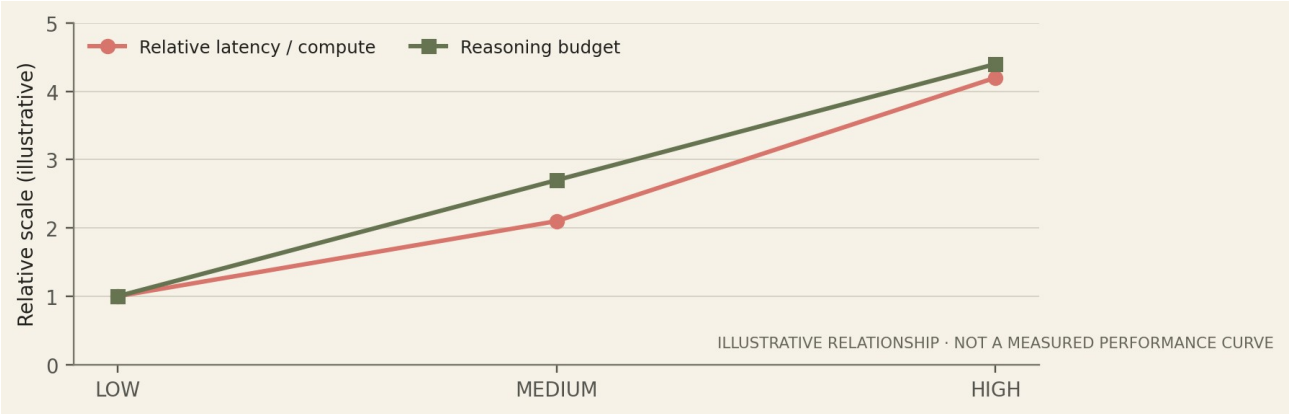


図 3. 推論予算と計算負荷の定性的な関係。測定された性能曲線ではない。

制御項目	技術的な意味
推論強度	タスク単位で設定し、トークンと時間に上限を設ける。
Harmony parser	ロール、チャネル、宛先、handoff マーカーを検証する。
Tool schema	引数を検証し、未知の関数を拒否する。
状態機械	呼び出し、retry、timeout、完了を追跡する。

- ユーザーデータ、ツール出力、開発者指示を別々の信頼境界で管理する。
- 取得した文書や Web ページ内の指示を含め、外部コンテンツは信頼しない。
- retry、停止条件、ツール呼び出し回数に上限を設ける。

生の内部推論を、確実な説明としてユーザーに見せない。OpenAI は raw CoT に幻覚やポリシーと矛盾する表現が含まれる可能性を警告している。簡潔な理由、ツール出力、引用、テスト証拠を提示する。

05 / OBLIVION RESEARCH

推論実行、メモリ、デプロイ

チェックポイント容量はリソース予算の最初の項目にすぎない

OpenAI は 20B のチェックポイントを 12.8 GiB、120B を 60.8 GiB と報告している。これは重みの保存容量であり、runtime 全体の必要量ではない。KV キャッシュ、コンテキスト長、同時系列数、allocator 断片化、量子化形式、offload 方針、runtime 実装も実際の必要量を左右する。

131K のコンテキスト上限は、すべての要求で全長を使うべきという意味ではない。長いコンテキストは KV キャッシュへの負荷を増やし、throughput を下げる可能性がある。技術的にロードできても、製品ワークフローでは遅すぎたり不安定だったり高価だったりする場合がある。

リソース要因	測定項目
重み	常駐 VRAM/RAM、形式、offload 比率
KV キャッシュ	コンテキスト長・同時実行数別のピークメモリ
レイテンシ	first token までの時間、p50/p95 完了時間
throughput	目標 batch での入出力トークン/秒
信頼性	OOM 率、再起動、不正な tool call
コスト/エネルギー	受理されたタスクあたりの GPU 時間とエネルギー

- OpenAI は 120B を単一 80GB GPU 向けとして位置付けている。運用保証と見なす前に runtime とコンテキスト条件を確認する。
- 20B についても公称 16GB だけで快適な実行を断定しない。VRAM、unified memory、system RAM のどれかを明確にする。
- GPU、driver、runtime、quantization、batch、context、生成予算を各 benchmark で記録する。

デプロイルール：モデルのロードだけでなく、製品の全経路を benchmark する。時間、メモリ、エネルギー、運用者介入あたりの成功タスク数を測定する。

06 / OBLIVION RESEARCH

安全性、信頼性、オープンウェイトの境界

重み自体が製品ポリシーを実行するわけではない

OpenAI の Model Card は、オープンウェイト運用では下流開発者に大きな責任が移ると指摘している。fine-tuning やシステム構成により挙動は変わり、公開元は派生デプロイ全体の保護策を集中管理できない。Apache 2.0 は広範な利用と変更を認めるが、公開利用ポリシーへの準拠は引き続き必要である。

Model Card によると、指示階層の評価や SimpleQA/PersonQA の事実性テストでは、両モデルは概して o4-mini を下回る。また raw internal reasoning に幻覚やポリシーに矛盾する表現が含まれる可能性がある。ツールやローカルファイルにアクセスする場合、この制約はより重要になる。

リスク	Oblivion に必要な制御
Prompt injection	取得内容はデータとして扱い、ポリシーとして扱わない。
過剰権限ツール	Allowlist、read-only を既定にし、書き込みは承認制。
事実誤認	出典、retrieval 確認、主張の検証。
危険なコード実行	Sandbox、リソース制限、無制限 shell/secret 禁止。
見えない障害	構造化ログ、イベント ID、制限付き retry、alert。

- OpenAI は一部の StrongREJECT jailbreak 評価では o4-mini と同等と報告する一方、ユーザーによる system 指示の上書きへの耐性はより弱いと報告している。
- 標準 120B は追跡対象の Preparedness カテゴリで指標上の「High」閾値に達しなかった。これは限定された評価結果であり、一般的な安全保証ではない。
- オープンウェイトは公開後に変更できる。製品側で権限、監視、moderation、監査証跡を実装する必要がある。

セキュリティ上の立場：安全性はシステム特性である。モデル、prompt、runtime、ツール、権限、データソース、人間のレビュー、監視の組み合わせに依存し、checkpoint 単独では成立しない。

07 / OBLIVION RESEARCH

Oblivion 向け参照アーキテクチャ

モデルは交換可能にし、ポリシーはモデルの外側に置く

Oblivion は gpt-oss を交換可能な推論 backend として扱うべきである。独立した orchestration 層が認証、ユーザー権限、モデル routing、コンテキスト構築、ツール認可、実行分離、証拠確認、監査イベントを担当する。この構成は基盤モデルが変わっても有効である。

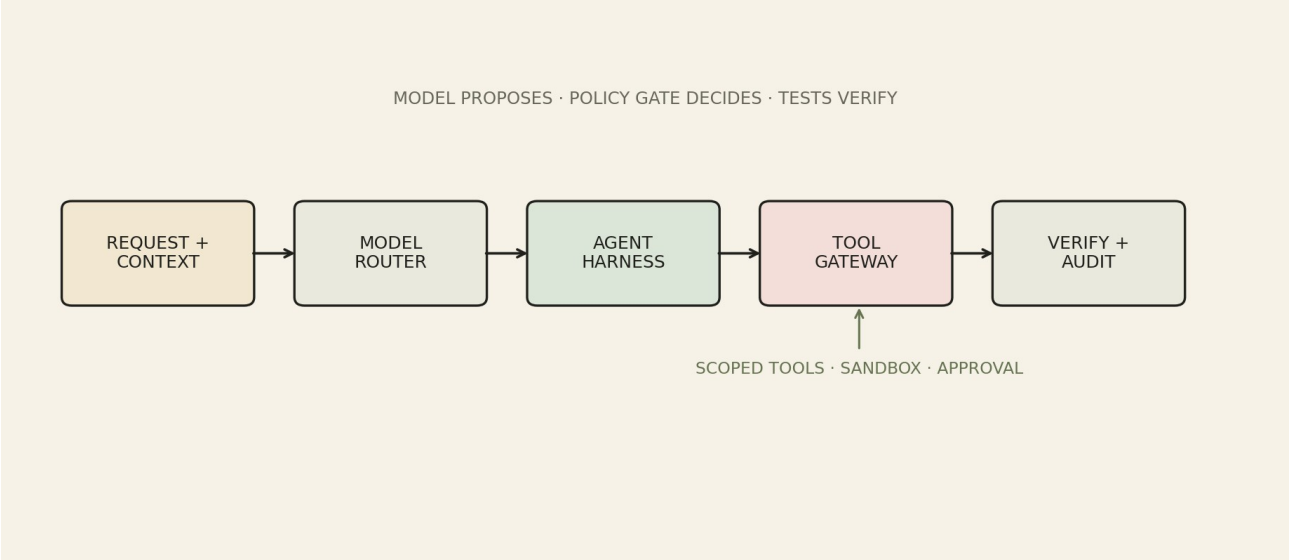


図 4. Oblivion Agent Harness に推奨される責務分離。

レイヤー	責務
Identity / Policy	セッション ID、tenant 境界、role 確認
Model Router	タスク、リスク、予算、測定品質に基づく 20B/120B 選択
Agent Harness	Harmony adapter、state machine、token/time budget、bounded retry
Tool Gateway	Allowlist、schema 検証、sandbox、承認
Verifier	テスト、引用、diff 確認、出力制約
Observability	不変監査イベント、metrics、trace、incident review

- 20B 候補用途：抽出、要約、初稿コード、範囲を限定したローカル分析、検証付き低リスクタスク。
- 120B 候補用途：難しい計画、複雑なデバッグ、深いコードレビュー、内部評価で品質向上が確認されたタスク。
- 削除、公開、外部メッセージ、資格情報変更、repository merge など状態を変更する操作は人間の承認を必須にする。

モデルは操作を提案できる。実行権限を判断するのは Tool Gateway である。モデルのスコアは実行許可ではない。

08 / OBLIVION RESEARCH

3 段階の批判的レビュー

主張を問い直し、証拠を確認し、設計を修正する

第 1 段階 - パラメータ数の前提を問い直す。初稿では 20B を「小型」、120B を「常に優位」と暗黙に扱っていたが、どちらも単純化しすぎている。20B の checkpoint は runtime overhead 前で 12.8 GiB であり、AIME 2025 のツールあり行では 120B を上回る一方、複数の知識・agentic タスクでは下回る。修正：普遍的な順位ではなく、タスク別の運用ポイントとして記述する。

第 2 段階 - benchmark の解釈を問い直す。公開スコアは、すべてのタスクで prompt、harness、反復回数、ハードウェアが同じであることを証明しない。高い推論強度は計算負荷を増やす。修正：各スコアに設定を付記し、Oblivion のタスクセットで再現してから本番モデルを選ぶ。

第 3 段階 - prompt だけの安全性を問い直す。変更可能な重みと外部ツール実行がある環境では、prompt だけでポリシーを確実に強制できない。修正：権限確認、sandbox、出力検証、人間承認をモデル外のコードで実施する。

- 実際の Oblivion ワークフローから匿名化した 100 件以上の評価タスクを作る。
- 日本語、ペルシャ語、英語、ドイツ語、韓国語を別々に評価し、英語の結果を他言語に外挿しない。
- prompt、runtime、tools、budget、hardware を固定し、low/medium/high を分けて報告する。
- タスク成功率、unit test、hallucination、injection 耐性、tool misuse、p50/p95 latency、ピークメモリ、エネルギーを測る。
- read-only を既定にし、副作用を伴う操作は承認制とし、監査ログを保存する。

最終見解：20B は資源効率が高く有用な推論能力を備える候補であり、120B はより高い容量と複数の難しい評価で強い結果を持つ。いずれも完成した製品ではない。Oblivion の価値は orchestration、検証、セキュリティ、測定された信頼性から生まれる。

09 / OBLIVION RESEARCH

方法論と主要参考資料

根拠の追跡可能性、再現性、制約

本レポートは Oblivion チーム向けの技術評価として再構成した。アーキテクチャと benchmark の数値は OpenAI の公開 gpt-oss Model Card に基づく。ホスティングと Safeguard 系列に関する現在の説明は、2026 年 10 月 26 日時点の OpenAI Help Center を参照した。Harmony の挙動は公開ドキュメントと照合した。

本レポートに含まれる benchmark を Oblivion が独立実行したわけではない。数値は harness の版、prompt、推論強度、tool 実装、quantization、hardware、decoding 設定、評価手順により変化し得る。図版は説明用の編集イラストであり、OpenAI の原図ではない。

- [1] OpenAI, gpt-oss-120b & gpt-oss-20b Model Card, 2025-08-05. https://deploymentsafety.openai.com/gpt-oss/a2
- [2] OpenAI, Introducing gpt-oss, 2025-08-05. https://openai.com/index/introducing-gpt-oss/
- [3] OpenAI Help Center, Open-Weight Models; 2026-10-26 閲覧. https://help.openai.com/
- [4] OpenAI, Harmony documentation and public repository. https://github.com/openai/harmony
- [5] OpenAI Cookbook, Harmony format. https://cookbook.openai.com/articles/openai-harmony
- [6] Hugging Face, Official OpenAI gpt-oss model repositories. https://huggingface.co/openai

解釈上の境界：本書は OpenAI の推奨、セキュリティ認証、独立 benchmark 報告ではない。製品公開前にライセンスと利用ポリシーの最新版を確認すること。