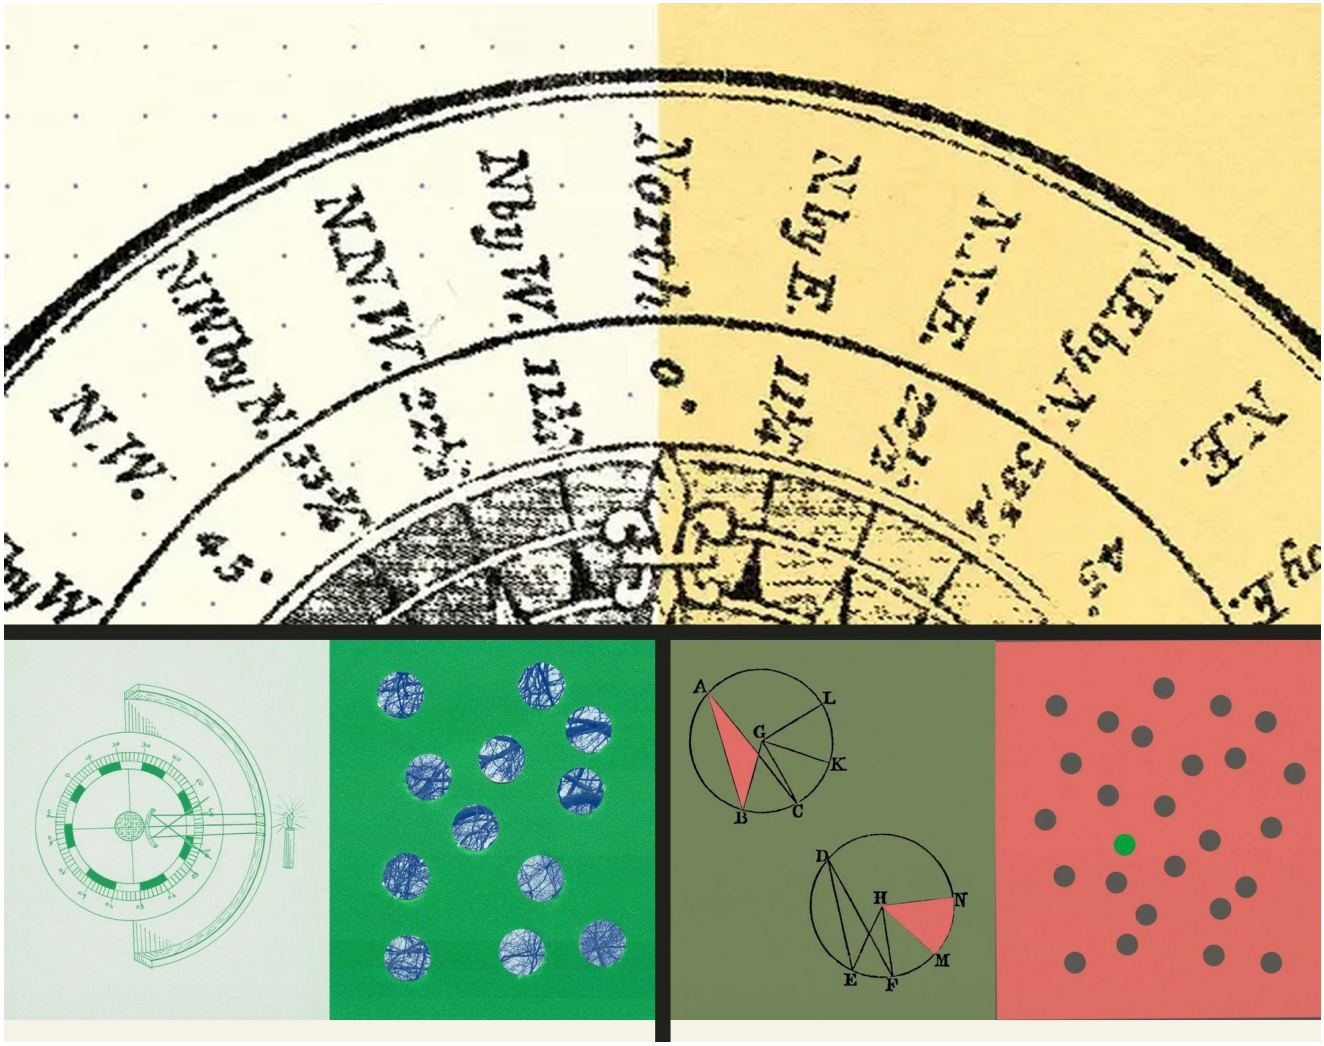


OBLIVION / MODEL SYSTEMS REPORT

GPT-OSS 20B & 120B

아키텍처, 추론 특성, 평가 및 배포 엔지니어링

Oblivion 엔지니어링 팀을 위한 비판적 기술 평가

한국어판 | 2026 년 10 월 26 일 | Research / 01

01 / OBLIVION RESEARCH

경영진 평가

두 가지 운영 지점, 하나의 엔지니어링 의사결정 프레임워크

gpt-oss 는 개발자가 직접 통제하는 인프라에서 가중치를 검토하고 호스팅하며 조정할 수 있는 오픈 웨이트 추론 모델 제품군이다. 그 가치는 파라미터 수만으로 설명되지 않는다. 희소 Mixture-of-Experts 계산, 조정 가능한 추론 강도, Harmony 기반 도구 상호작용, Apache 2.0 라이선스(공개된 사용 정책 준수 조건)가 함께 기술적 가치를 형성한다.

20B 와 120B 는 서로 다른 운영 지점으로 보아야 한다. 소형 모델은 호스팅이 쉽고 범위가 제한된 추론 작업에서 경쟁력이 높다. 대형 모델은 전체 용량이 크고 지식, 코딩, 도구 사용 평가에서 더 높은 결과를 보이는 경우가 많지만 훨씬 많은 메모리와 연산 자원이 필요하다. 절대적인 승자는 없다.

지표	20B	120B
전체 파라미터	20.91B	116.83B
토큰당 활성 파라미터	3.61B	5.13B
체크포인트 크기	12.8 GiB	60.8 GiB
토큰당 선택 전문가	4	4

- 오픈 웨이트는 완전히 재현 가능한 오픈소스 학습 공개를 뜻하지 않는다. 전체 사전학습 코퍼스와 완전한 학습 파이프라인은 공개되지 않았다.
- 활성 파라미터는 토큰마다 선택되는 계산을 설명하며 저장해야 할 전체 가중치 크기를 뜻하지 않는다.
- gpt-oss 는 ChatGPT 또는 OpenAI API 를 통해 제공되지 않는다. 운영 책임은 운영자 또는 호스팅 제공자에게 있다.

엔지니어링 결론: 로컬 및 자원 제약 워크플로의 첫 후보로 20B 를 검토한다. 어려운 지식 문제, 다단계 코딩, 그리고 Oblivion 측정 결과가 인프라 비용 대비 품질 향상을 입증하는 작업에는 120B 를 고려한다. 모델명이나 파라미터 수가 아니라 작업과 증거에 따라 선택한다.

범위 업데이트: OpenAI 는 gpt-oss-safeguard-20b 및 -120b 도 연구 프리뷰로 안내한다. 이 모델은 정책 기반 안전성 분류용이며 본 보고서의 범용 20B/120B 모델을 대체하지 않는다.

02 / OBLIVION RESEARCH

아키텍처와 희소 계산

활성 파라미터는 모델 크기와 같지 않다

두 모델은 Mixture-of-Experts(MoE) 블록을 사용하는 자기회귀 Transformer 언어 모델이다. 각 토큰에 대해 학습된 라우터가 더 큰 후보 집합에서 네 개의 전문가를 선택한다. 선택된 전문가만 해당 토큰의 전문 계산에 참여하지만 공유 계층과 Attention 도 전체 forward pass 에 포함된다.

희소 라우팅은 전체 모델 용량과 토큰당 전문가 계산 사이의 비율을 개선한다. 그러나 체크포인트를 활성 파라미터 수만큼 줄이지는 않는다. 모든 전문가 가중치는 메모리에 존재하거나 runtime 에서 로드 또는 offload 되어야 한다.

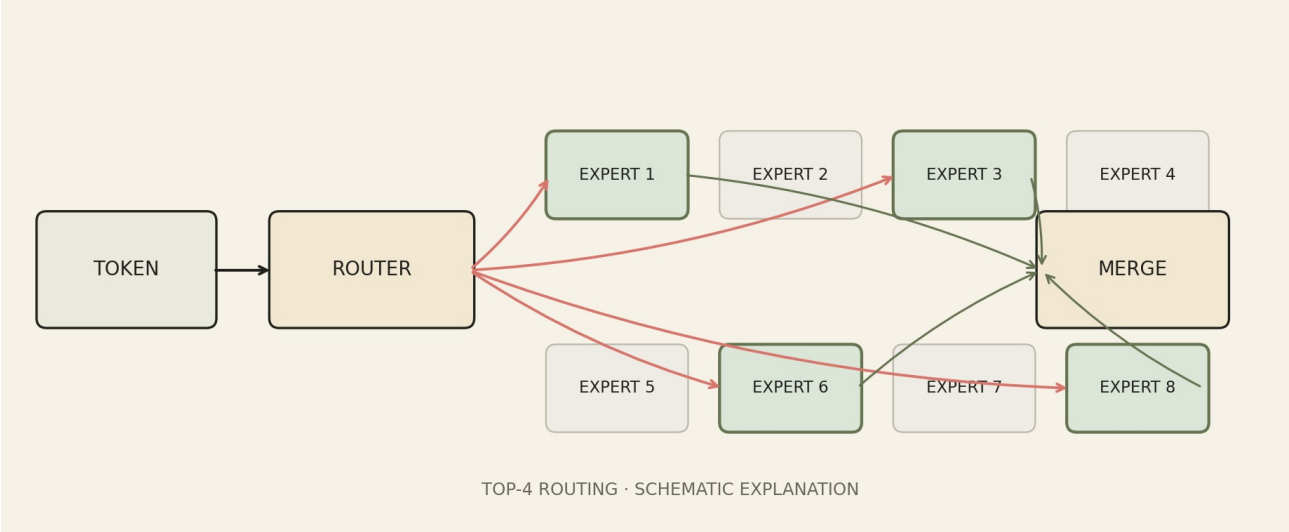


그림 1. Top-4 MoE 라우팅 개념도. 내부 블록 그래프를 그대로 복제한 것은 아니다.

아키텍처 항목	20B	120B
Transformer 계층	24	36
MoE 블록당 전문가	32	128
토큰당 선택 전문가	4	4
Query 헤드	64	64
Key/Value 헤드	8	8
Attention 헤드 차원	64	64

- Attention 은 로컬 banded window 와 dense attention 패턴을 교차 사용한다. 로컬 창 너비는 128 토큰이다.
- Grouped-Query Attention 은 Query 헤드 64 개와 Key/Value 헤드 8 개를 사용한다.
- RoPE 와 YaRN 은 dense 계층에서 최대 131,072 토큰의 컨텍스트를 지원하는 것으로 보고됐다.
- 구성에는 RMSNorm, Pre-LN, SwiGLU 및 MoE 가중치에 대한 MXFP4 사후 학습 양자화가 포함된다.

해석: 3.61B 와 5.13B 는 토큰당 활성 계산을 나타내는 유용한 지표지만 RAM/VRAM 요구량의 신뢰할 만한 추정치는 아니다. 메모리 계획에는 체크포인트 크기와 함께 KV 캐시, runtime 버퍼, batching, 운영체제 오버헤드를 포함해야 한다.

03 / OBLIVION RESEARCH

평가: 공개 점수가 말해주는 것

높은 추론 설정 결과의 비교 해석

아래 표는 OpenAI Model Card 의 높은 추론 설정에서 선택한 값을 재현한 것이다. 도구 사용/미사용 행은 서로 다른 평가 조건이다. 서로 다른 benchmark 점수는 직접 비교할 수 없으며 공급자가 공개한 값은 Oblivion 이 독립적으로 재현한 결과가 아니다.

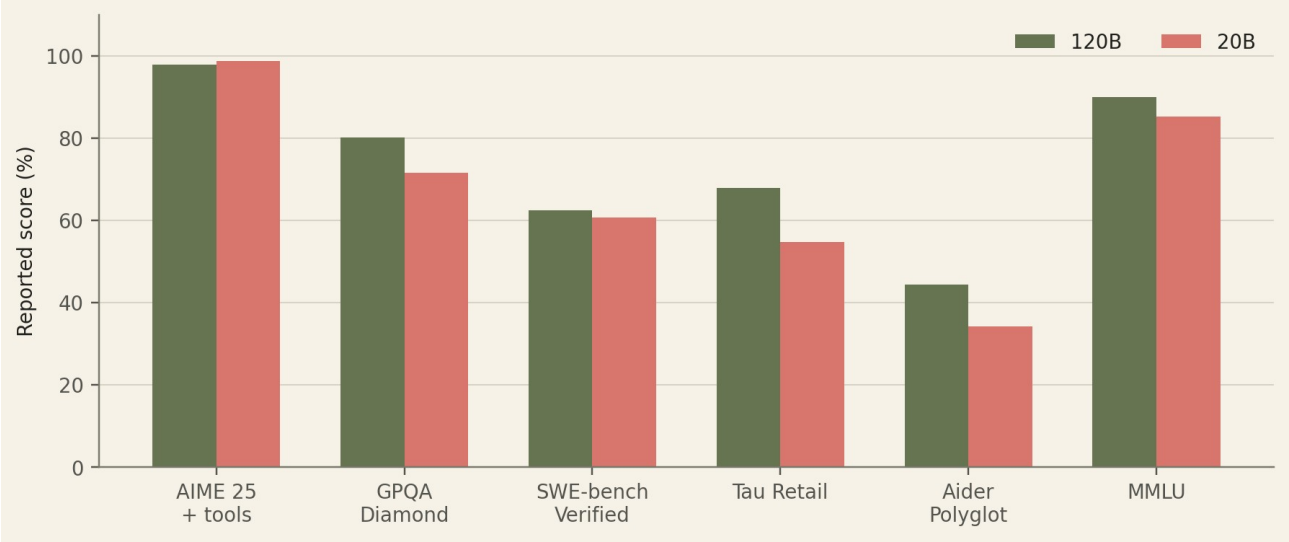


그림 2. OpenAI 공개 Model Card 에서 재구성한 선택 점수. 도구를 사용한 AIME 2025 에서는 20B 가 근소하게 높다.

Benchmark / 조건	120B	20B	우세
AIME 2025 · 도구 사용	97.9	98.7	20B
GPQA Diamond · 도구 없음	80.1	71.5	120B
SWE-bench Verified	62.4	60.7	120B
τ-Bench Retail	67.8	54.8	120B
Aider Polyglot	44.4	34.2	120B
MMLU	90.0	85.3	120B

- 120B 는 GPQA Diamond, τ-Bench Retail, Aider Polyglot 에서 더 큰 우위를 보인다.
- 20B 는 도구 사용 AIME 2025 행에서 근소하게 앞선다. 이는 특정 작업의 결과이지 전반적인 역전을 뜻하지 않는다.
- Codeforces Elo 는 도구 사용 시 2622 대 2516, 미사용 시 2463 대 2230 으로 보고됐다(120B 대 20B).

이 표를 단일 순위표로 압축하지 말아야 한다. 저장소 변경, 로컬 추출, 다국어 지원, 도구 신뢰성, 지연 시간 등 Oblivion 의 실제 작업 구성에 따라 모델 순위는 달라질 수 있다.

04 / OBLIVION RESEARCH

추론, Harmony 및 도구 사용

도구 호출 기능만으로 신뢰할 수 있는 에이전트가 되지는 않는다

추론 강도는 low, medium, high 로 조정할 수 있다. 추론량을 늘리면 어려운 문제의 정확도가 향상될 수 있지만 생성 토큰, 응답 지연, 계산 비용도 증가하는 경우가 많다. OpenAI 는 높은 추론 설정에서 gpt-oss-20b 가 AIME 문제당 평균 20,000 개가 넘는 chain-of-thought 토큰을 사용했다고 보고했다. 이는 비용과 지연에 관한 경고이지 제품 예산이 아니다.

모델은 메시지 경계, 역할, 채널, 제어 흐름 마커를 담는 직렬화된 대화 형식인 Harmony 를 사용한다. 도구 호출은 도구를 수신자로 지정한 assistant 메시지이며 도구 응답은 도구 이름으로 돌아온다. 통합 계층은 전체 스트림을 일반 텍스트로 취급하지 말고 제어 흐름을 정확히 파싱해야 한다.

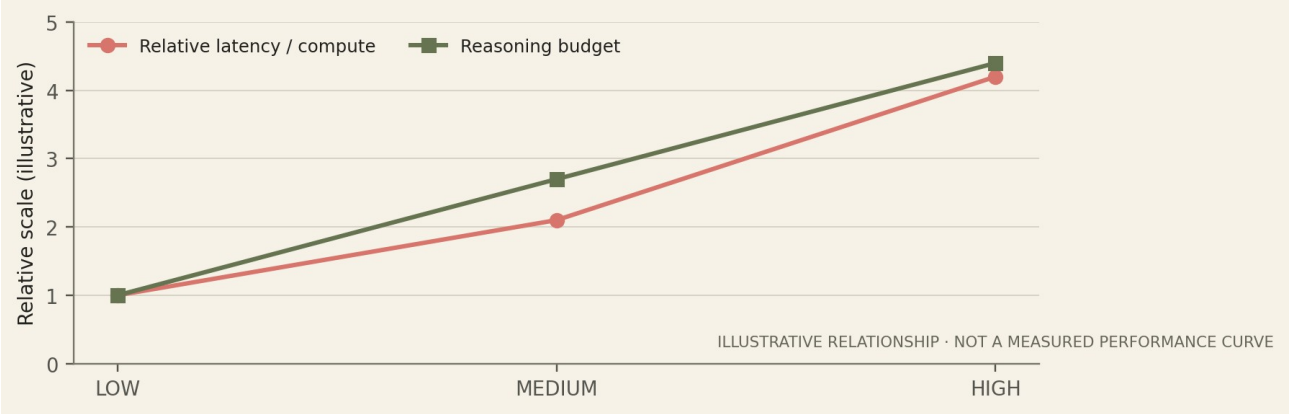


그림 3. 추론 예산과 계산량의 정성적 관계. 측정된 성능 곡선이 아니다.

제어 영역	엔지니어링 의미
추론 강도	작업별 설정, 토큰 및 시간 상한 설정
Harmony parser	역할, 채널, 수신자, handoff 마커 검증
도구 schema	인수 검증 및 미등록 함수 거부
상태 머신	호출, 재시도, timeout, 완료 추적

- 사용자 데이터, 도구 출력, 개발자 지시를 별도의 신뢰 영역으로 유지한다.
- 검색된 문서와 웹페이지에 포함된 지시를 포함해 외부 콘텐츠를 신뢰하지 않는다.
- 재시도, 중단 조건, 도구 호출 수를 제한한다.

원시 내부 추론을 확정적인 설명으로 사용자에게 노출하지 말아야 한다. OpenAI 는 raw CoT 에 환각이나 정책과 일치하지 않는 표현이 포함될 수 있다고 경고한다. 간결한 근거, 도구 출력, 인용 및 테스트 증거를 제시한다.

05 / OBLIVION RESEARCH

추론 실행, 메모리 및 배포

체크포인트 크기는 리소스 예산의 첫 항목일 뿐이다

OpenAI 는 20B 의 체크포인트 크기를 12.8 GiB, 120B 를 60.8 GiB 로 보고한다. 이는 가중치 저장 크기이지 전체 runtime 요구량이 아니다. KV 캐시, 컨텍스트 길이, 동시 시퀀스, allocator 단편화, 양자화 형식, offload 정책, runtime 구현도 실제 요구량에 영향을 준다.

131K 컨텍스트 한계가 모든 요청에서 전체 길이를 사용해야 한다는 뜻은 아니다. 긴 컨텍스트는 KV 캐시 부담을 높이고 throughput 을 낮출 수 있다. 기술적으로 로드할 수 있어도 제품 워크플로에서는 너무 느리거나 불안정하거나 비용이 클 수 있다.

리소스 요소	측정 항목
가중치	상주 VRAM/RAM, 형식, offload 비율
KV 캐시	컨텍스트 길이 및 동시성별 최대 메모리
지연 시간	첫 토큰 시간, p50/p95 완료 시간
처리량	목표 batch 에서 초당 입력/출력 토큰
신뢰성	OOM 비율, 재시작, 잘못된 도구 호출
비용/에너지	수락된 작업당 GPU 시간과 에너지

- OpenAI 는 120B 를 단일 80GB GPU 용으로 안내한다. 운영 보장으로 간주하기 전에 runtime 과 컨텍스트 조건을 확인해야 한다.
- 20B 역시 명목상 16GB 라는 수치만으로 원활한 실행을 단정하지 않는다. VRAM, unified memory, 시스템 RAM 중 무엇인지 확인한다.
- 각 benchmark 에 GPU, 드라이버, runtime 버전, 양자화, batch, 컨텍스트, 생성 예산을 기록한다.

배포 원칙: 모델 로드만이 아니라 제품의 전체 경로를 benchmark 한다. 지연, 메모리, 에너지, 운영자 개입 단위당 성공 작업 수를 측정한다.

06 / OBLIVION RESEARCH

안전성, 신뢰성 및 오픈 웨이트의 경계

가중치 자체가 제품 정책을 강제하지는 않는다

OpenAI Model Card 는 오픈 웨이트 배포에서 상당한 책임이 하위 개발자에게 이전된다고 설명한다. fine-tuning 과 시스템 구성에 따라 동작이 달라질 수 있으며 공개자는 파생 배포 전체의 보호 장치를 중앙에서 강제할 수 없다. Apache 2.0 은 폭넓은 사용과 수정을 허용하지만 공개된 사용 정책은 계속 적용된다.

Model Card 에 따르면 두 모델은 지시 계층 평가와 SimpleQA/PersonQA 사실성 테스트에서 대체로 o4-mini 보다 낮다. 또한 원시 내부 추론에 환각이나 정책과 일치하지 않는 표현이 포함될 수 있다고 경고한다. 모델이 도구나 로컬 파일에 접근할 경우 이러한 한계는 더 중요하다.

위험	Oblivion 필수 통제
Prompt injection	검색된 콘텐츠는 데이터로 취급하고 정책으로 취급하지 않는다.
과도한 도구 권한	Allowlist, 기본 read-only, 쓰기 작업의 명시적 승인
사실 오류	출처 인용, 검색 확인, 주장 검증
안전하지 않은 코드 실행	Sandbox, 리소스 제한, 무제한 shell/secret 금지
조용한 장애	구조화 로그, 이벤트 ID, 제한된 재시도, 경보

- OpenAI 는 일부 StrongREJECT jailbreak 평가에서 o4-mini 와 비슷한 결과를 보고했지만 시스템 지시를 덮어쓰려는 사용자 시도에 대한 저항은 더 약하다고 보고했다.
- 기본 120B 는 추적된 Preparedness 범주에서 지표상 “High” 임계값에 도달하지 않았다. 이는 제한된 평가 결과이지 보편적인 안전 보장이 아니다.
- 오픈 웨이트는 공개 후 수정될 수 있다. 제품 자체가 권한, 모니터링, moderation, 감사 기록을 구현해야 한다.

보안 입장: 안전성은 시스템의 속성이다. 모델, prompt, runtime, 도구, 권한, 데이터 소스, 사람의 검토 및 모니터링에 달려 있으며 체크포인트만으로 보장되지 않는다.

07 / OBLIVION RESEARCH

Oblivion 참조 아키텍처

모델은 교체 가능하게, 정책은 모델 외부에 둔다

Oblivion 은 gpt-oss 를 교체 가능한 추론 backend 로 취급해야 한다. 별도의 orchestration 계층이 인증, 사용자 권한, 모델 라우팅, 컨텍스트 구성, 도구 승인, 실행 격리, 증거 확인, 감사 이벤트를 담당한다. 이 구조는 기반 모델이 변경되어도 유효하다.

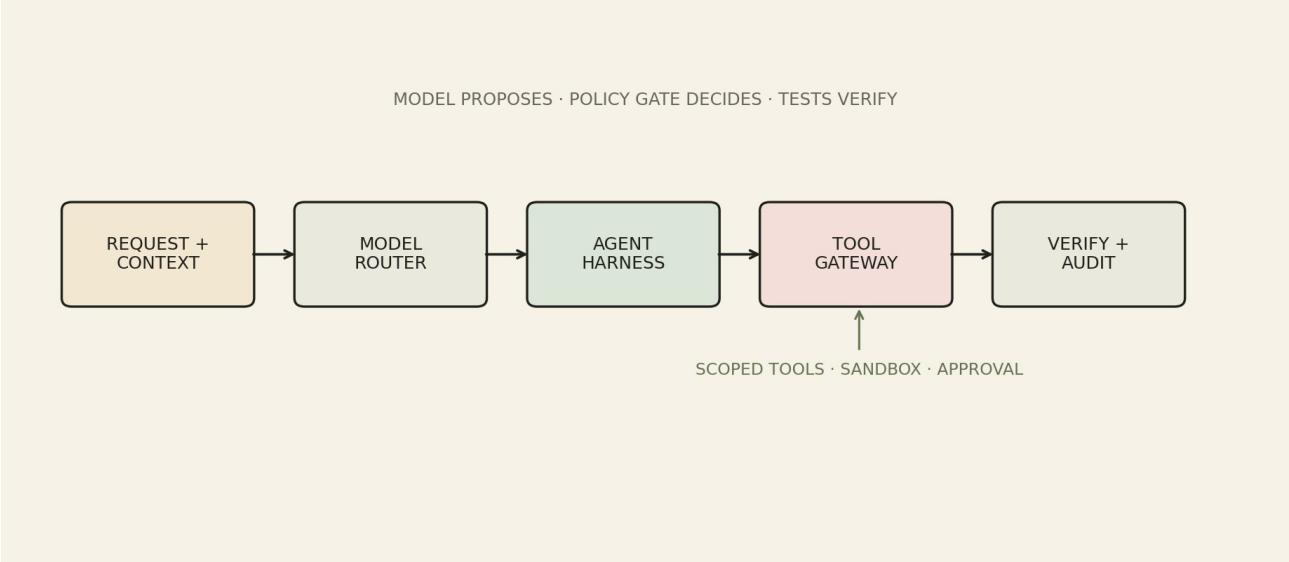


그림 4. Oblivion Agent Harness 에 권장하는 책임 분리.

계층	책임
Identity / Policy	세션 ID, tenant 경계, 역할 확인
Model Router	작업, 위험, 예산, 측정된 품질에 따른 20B/120B 선택
Agent Harness	Harmony 어댑터, 상태 머신, 토큰/시간 예산, 제한된 재시도
Tool Gateway	Allowlist, schema 검증, sandbox, 승인
Verifier	테스트, 인용, diff 검토, 출력 제약
Observability	변조 방지 감사 이벤트, 지표, trace, incident review

- 20B 후보 역할: 추출, 요약, 코드 초안, 범위가 제한된 로컬 분석, 검증이 포함된 저위험 작업.
- 120B 후보 역할: 어려운 계획, 복잡한 디버깅, 심층 코드 리뷰, 내부 평가에서 품질 향상이 확인된 작업.
- 삭제, 게시, 외부 메시지, 자격 증명 변경, 저장소 병합 등 상태 변경 작업은 사람의 승인을 요구한다.

모델은 작업을 제안할 수 있지만 실행 권한은 Tool Gateway 가 결정한다. 모델 점수는 실행 허가가 아니다.

08 / OBLIVION RESEARCH

3 단계 비판적 검토

주장을 재검토하고 증거를 확인한 뒤 설계를 수정

1 차 - 파라미터 수에 대한 가정을 재검토한다. 초안은 20B 를 “작은 모델”, 120B 를 “항상 더 좋은 모델”로 암묵적으로 취급했다. 두 해석 모두 불완전하다. 20B 체크포인트는 runtime 오버헤드 전 12.8 GiB 이며 AIME 2025 도구 사용 항목에서는 120B 보다 높지만 여러 지식 및 agentic 작업에서는 낮다. 수정: 보편적 순위 대신 작업별 운영 지점으로 설명한다.

2 차 - benchmark 해석을 재검토한다. 공개 점수는 모든 작업에서 prompt, harness 버전, 반복 횟수, 하드웨어가 동일했음을 증명하지 않는다. 높은 추론 강도는 연산량을 높인다. 수정: 각 점수에 조건을 표시하고 Oblivion 작업 집합에서 재현한 뒤 기본 모델을 선택한다.

3 차 - prompt 만으로 안전성을 확보한다는 가정을 재검토한다. 수정 가능한 가중치와 외부 도구 실행이 있는 환경에서 prompt 만으로 정책을 신뢰성 있게 강제할 수 없다. 수정: 권한 확인, sandbox, 출력 검증, 사람의 승인을 모델 외부 코드에 구현한다.

- 실제 Oblivion 워크플로에서 익명화한 최소 100 개 평가 작업을 만든다.
- 페르시아어, 영어, 독일어, 일본어, 한국어를 별도로 시험하고 영어 점수를 다른 언어에 일반화하지 않는다.
- prompt, runtime, 도구, 예산, 하드웨어를 고정하고 low/medium/high 를 구분해 보고한다.
- 작업 성공률, unit test, 환각, injection 저항, 도구 오용, p50/p95 지연, 최대 메모리, 에너지를 측정한다.
- read-only 를 기본으로 하고 부작용은 승인 후 실행하며 전체 감사 로그를 보존한다.

최종 입장: 20B 는 자원 효율이 높고 의미 있는 추론 능력을 갖춘 후보이며, 120B 는 더 큰 용량과 여러 어려운 평가에서 강점을 보인다. 어느 모델도 완성된 제품은 아니다. Oblivion 의 가치는 orchestration, 검증, 보안, 측정된 신뢰성에서 나와야 한다.

09 / OBLIVION RESEARCH

방법론 및 주요 참고자료

증거 출처, 재현 가능성 및 한계

본 보고서는 Oblivion 팀을 위한 엔지니어링 평가로 다시 작성되었다. 아키텍처와 benchmark 수치는 OpenAI 의 공개 gpt-oss Model Card 에 근거한다. 현재 호스팅 및 Safeguard 계열에 관한 설명은 2026 년 10 월 26 일 기준 OpenAI Help Center 를 참조한다. Harmony 동작은 공개 OpenAI 문서와 대조했다.

본 보고서의 benchmark 는 Oblivion 이 독립적으로 실행한 것이 아니다. 결과는 harness 버전, prompt 설계, 추론 강도, 도구 구현, 양자화, 하드웨어, decoding 설정, 평가 프로토콜에 따라 달라질 수 있다. 도표는 설명을 위한 편집용 그림이며 OpenAI 의 원본 도표가 아니다.

- [1] OpenAI, gpt-oss-120b & gpt-oss-20b Model Card, 2025-08-05. https://deploymentsafety.openai.com/gpt-oss/a2
- [2] OpenAI, Introducing gpt-oss, 2025-08-05. https://openai.com/index/introducing-gpt-oss/
- [3] OpenAI Help Center, Open-Weight Models; 2026-10-26 확인. https://help.openai.com/
- [4] OpenAI, Harmony 문서 및 공개 저장소. https://github.com/openai/harmony
- [5] OpenAI Cookbook, Harmony format. https://cookbook.openai.com/articles/openai-harmony
- [6] Hugging Face, OpenAI 공식 gpt-oss 모델 저장소. https://huggingface.co/openai

해석의 범위: 본 문서는 OpenAI 의 보증, 보안 인증 또는 독립 benchmark 보고서가 아니다. 제품 출시 전 최신 라이선스와 사용 정책을 확인해야 한다.